

RELATÓRIO COM O DETALHAMENTO DAS ETAPAS DESENVOLVIDAS NO MVP

ALUNA: Elisandra André Maranhe
SPRINT: Engenharia de Dados – PUC RIO
RA: 4052026000054

1. Contexto de Negócios e Perguntas (Etapa 2 e 4.1)

Trabalho em uma instituição educacional de ensino superior que tem vários cursos e o nosso foco de análise de mercado nesse momento são os cursos de pós-graduação, haja vista estarmos fazendo uma reestrutura nas ofertas.

Atualmente, a nossa instituição investe no desenvolvimento de novos cursos de pós-graduação baseando-se, muitas vezes, em intuição ou em tendências genéricas de mercado. No entanto, entendo que corremos o risco de faturar menos por oferecer produtos acadêmicos para um público que exige soluções altamente práticas e voltadas para o mercado corporativo.

Nesse sentido, o problema central que perpassa todas as perguntas de negócio que apresentarei a seguir é a **desconexão entre a gestão do ciclo de vida do aluno (LTV – Lifetime Value) e a previsibilidade de receita na conversão de egressos para a Pós-Graduação**.

Diante **deste problema**, entre as medidas iniciais cabíveis, reuni-me com o Conselho Diretor da instituição para levantarmos análises que possam nos ajudar com respostas ao cenário que vivenciamos hoje. Trabalhamos com Sistemas ERP, CRM e Plataforma de Egressos gerando dados importantes para essa análise. Porém, era preciso entendermos quais as principais perguntas de negócio que poderiam ser respondidas (ou não) a partir destes dados, e que pudessem nos guiar em ações práticas para sanar o nosso problema inicial.

A partir desta reunião, consegui levantar as perguntas de negócio e dividi-las em quatro categorias. As quatro não abordam problemas isolados; pelo contrário, elas tentam resolver a ineficiência na alocação de esforços de marketing e vendas (Up-sell) por falta de um modelo de propensão e segmentação preditiva do Alumni. Esse é o objetivo final de todo o processo de análise, ou seja, iniciar a análise com respostas diagnóstica e chegar a um modelo preditivo futuramente (esta parte deixarei para um segundo momento, pois envolverá a criação de um modelo de Machine Learning).




Figura 1 – Categorias levantadas para análise de dados.

Portanto, descrevo a seguir as perguntas de negócio que tem como objetivo serem respondidas a partir da análise dos dados trabalhados neste MVP.

A. Timing e Propensão (Potencial de conversão e captação de pós-graduação)

- Setores envolvidos: Marketing e Financeiro
- Perguntas de negócio:
 - Qual é a taxa de conversão (*potencial_matricula_pos*) por curso (*nome_curso*) e por área do conhecimento?
 - Qual o tempo ideal após a graduação (*meses_desde_formacao*) em que os egressos demonstram maior intenção de matrícula?
 - Ex-bolsistas de graduação (*bolsista_graduacao*) possuem maior probabilidade de continuar os estudos em comparação aos não bolsistas?

B. Capacidade Financeira (Empregabilidade e perfil socioeconômico)

- Setores envolvidos: Marketing e Financeiro
- Perguntas de negócio:
 - Qual é a renda média e a distribuição de cargos (*nivel_cargo*) por curso e por modalidade (*modalidade_graduacao*)?
 - Existe correlação entre o valor da mensalidade da graduação (*mensalidade_base*) e o retorno financeiro atual do egresso (*renda_mensal_estimada*)?
 - Quais cursos geram maior inserção na iniciativa privada vs. setor público vs. profissionais autônomos?

C. Engajamento e Lealdade (Satisfação e Engajamento da Comunidade Alumni)

- Setores envolvidos: Acadêmico e Marketing
- Perguntas de negócio:
 - Como o NPS da graduação (*satisfacao_graduacao_nps*) se relaciona com a pontuação de engajamento do ex-aluno (*engajamento_alumni_score*)?
 - Promotores do curso (NPS 9-10) apresentam maior propensão a se matricular na pós-graduação do que detratores?
 - A modalidade de ensino (EAD vs. Presencial) impacta o nível de engajamento pós-formação?

D. Atratividade Geográfica (Geografia e Oportunidades de Mercados Regionais)

- Setores envolvidos: Acadêmico e Marketing
- Perguntas de negócio:
 - Quais estados (*uf_residencia*) concentram os egressos com maior potencial de matrícula para campanhas regionalizadas de marketing?

- Qual a distribuição espacial dos profissionais por área de atuação e renda média?


1.1. Sobre os datasets utilizados: tipo, estrutura e licença

Para poder responder a todas estas perguntas, busquei trabalhar com dados de uma de nossas plataformas (ERP). Atualmente, ela não faz integração direta com nenhuma ferramenta que automatize o ETL. Mas a intenção futura com este projeto é mostrar o ganho que podemos ter neste sentido para o Conselho Diretor da instituição. Sendo assim, os datasets foram extraídos em formato “csv” (forma bruta), baixados para meu computador e feito a ingestão manual futura no Databricks (mais detalhes serão apresentados adiante).

Trabalhei com dois *datasets* em que o primeiro apresentava 15 atributos com um total de 11.660 linhas, e o segundo 5 atributos e 16 linhas, como mostram as Figuras 2 e 3. Ambos podem ser acessados diretamente no GitHub pelo link:

https://github.com/elis2637/posgrad_pucrio/tree/main/sprint_engenharia_dados/dataset.

Para que pudessem ser utilizados respeitando a LGPD, os ID reais dos egressos, bem como seus respectivos nomes foram eliminados. Com isso, foi inserida uma coluna com IDs sequenciados de 1 a 11.660, mantendo o anonimato dos egressos. Estes ajustes foram feitos antes da ingestão no Databricks, para que fosse possível disponibilizá-los, também, no GitHub, haja vista ser um repositório público.



	A	B	C	D	E
	id_curso	nome_curso	area_conhecimento	duracao_semestres	mensalidade_base
1	101	Ciência da Computação	Tecnologia	8	1200
2	102	Análise e Desenvolvimento de Sistemas	Tecnologia	5	850
3	103	Sistemas de Informação	Tecnologia	8	1050
4	104	Engenharia de Software	Tecnologia	9	1350
5	201	Engenharia Civil	Exatas	10	1500
6	202	Engenharia de Produção	Exatas	10	1400
7	203	Matemática Aplicada	Exatas	8	900
8	204	Estatística e Ciência de Dados	Exatas	8	1150
9	301	Administração	Humanas	8	980
10	302	Direito	Humanas	10	1600
11	303	Psicologia	Humanas	10	1300
12	304	Pedagogia	Humanas	8	750
13	401	Medicina Veterinária	Biológicas	10	2200
14	402	Enfermagem	Biológicas	9	1250
15	403	Biomedicina	Biológicas	8	1100
16	404	Nutrição	Biológicas	8	1000

Figura 2 – Dataset cursos (csv) gerado de Plataforma ERP da instituição.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	id_egresso	id_curso	id_universidade	nome_aluno	nome_curso	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao
2	1	103	2020-02-02	MD	109	21	Sem vinculo	109	21	Sem vinculo	109	21	Sem vinculo	109	21
3	2	204	2020-11-04	PH	87	25	Junior	5282.18	Estatas	Historia	Iniciativa Privada	8	31	0	0
4	3	201	2020-11-21	SC	88	28	Sem vinculo	0	Humanas	Desempenho	Desempenho	5	100	0	0
5	4	203	2020-08-04	RJ	20	25	Junior	2376.19	Estatas	Presencial	Sector Publico	5	21	0	0
6	5	103	2020-02-02	SP	112	20	Geobio	10143.79	Tecnologia	Presencial	Iniciativa Privada	9	82	1	0
7	6	104	2020-02-02	SP	77	20	Geobio	16170.07	Tecnologia	Presencial	ONG	5	84	1	0
8	7	101	2020-05-17	PH	86	27	Senior	12145.15	Tecnologia	Presencial	Iniciativa Privada	5	99	0	0
9	8	101	2020-11-30	SC	26	28	Plano	5125.08	Tecnologia	EAD	Iniciativa Privada	5	20	0	0
10	9	103	2020-02-02	SP	105	24	Geobio	17082.71	Tecnologia	EAD	AutonomiaPJ	5	79	0	0
11	10	302	2020-04-02	SP	88	32	Sem vinculo	0	Humanas	Presencial	Desempenho	5	95	0	0
12	11	403	2020-02-02	GO	82	27	Geobio	18843.01	Biologicos	EAD	Iniciativa Privada	5	20	0	0
13	12	303	2020-04-02	SC	80	33	Geobio	15076.08	Humanas	EAD	Iniciativa Privada	10	27	1	1
14	13	303	2020-02-02	BA	80	27	Senior	12382.27	Humanas	EAD	AutonomiaPJ	8	18	0	0
15	14	203	2020-02-02	PH	83	29	Geobio	16132.06	Estatas	EAD	Sector Publico	8	13	1	0
16	15	104	2020-10-31	SP	105	35	Geobio	17085.8	Tecnologia	EAD	ONG	8	86	0	0
17	16	101	2020-07-11	MG	109	36	Senior	8070.4	Tecnologia	Presencial	Sector Publico	9	23	0	0
18	17	104	2020-02-02	MG	28	23	Plano	4354.88	Tecnologia	EAD	Iniciativa Privada	6	19	0	0
19	18	304	2020-06-17	SP	8	27	Sem vinculo	0	Humanas	EAD	Desempenho	10	31	1	0
20	19	404	2020-08-07	RJ	27	29	Junior	1824.79	Biologicos	Presencial	Iniciativa Privada	5	73	0	0
21	20	203	2020-12-04	PH	58	29	Plano	8206.38	Estatas	Presencial	Iniciativa Privada	8	51	1	0
22	21	302	2020-06-08	SP	7	25	Junior	2385.1	Estatas	Presencial	Iniciativa Privada	6	84	0	0
23	22	201	2020-09-23	PH	83	30	Senior	13489.3	Estatas	Presencial	Sector Publico	6	94	1	0
24	23	202	2020-02-02	MG	113	35	Geobio	15191.28	Estatas	EAD	Iniciativa Privada	7	51	1	0
25	24	304	2020-09-18	BA	20	22	Plano	8915.79	Humanas	Presencial	AutonomiaPJ	5	100	1	0
26	25	304	2020-07-18	SP	43	30	Senior	12382.08	Humanas	Presencial	Iniciativa Privada	7	37	1	0
27	26	302	2020-03-18	SP	7	23	Junior	4887.38	Humanas	Presencial	Iniciativa Privada	7	78	0	0
28	27	302	2020-08-01	MG	89	31	Geobio	17087.04	Humanas	Presencial	AutonomiaPJ	8	94	1	1
29	28	202	2020-04-02	SP	85	29	Senior	15871.84	Estatas	EAD	Iniciativa Privada	9	91	1	0
30	29	404	2020-05-02	PH	26	25	Plano	7176.13	Biologicos	EAD	Iniciativa Privada	6	9	0	0
31	30	304	2020-07-25	PH	38	23	Junior	2843.81	Humanas	Presencial	Iniciativa Privada	5	89	0	0
32	31	201	2020-07-28	SP	81	28	Sem vinculo	0	Estatas	Historia	Desempenho	5	14	1	0
33	32	201	2020-12-08	RJ	83	29	Plano	4523.31	Estatas	Presencial	Iniciativa Privada	5	48	0	0
34	33	404	2020-08-08	RJ	27	25	Plano	8038.08	Biologicos	EAD	Iniciativa Privada	9	50	1	0
35	34	202	2020-05-18	SP	113	30	Geobio	16144.01	Estatas	EAD	Iniciativa Privada	7	9	0	0
36	35	202	2020-01-08	GO	94	21	Geobio	18229.24	Estatas	Presencial	Iniciativa Privada	4	20	1	0

Figura 3 – Dataset egressos (csv) gerado de Plataforma ERP da instituição.

2. Carga do Dados (Etapa 4.2)

Inicialmente, havia pensado em fazer um Job no Databricks para automatizar a ingestão de dados incremental, porém achei melhor subir os datasets manualmente, já que ainda precisaria de uma autorização do Conselho Diretor para a continuidade da geração dos dados, para além dos 11.660 que tive de autorização como base de uma POC. Diante disso, fiz a ingestão direta dos arquivos em Volume do Unity Catalog da Camada Bronze (utilizei a Estrutura Medalhão para aplicação do pepiline). E a partir dele, gerei as tabelas bronze como mostrado pelo código pyspark.sql a seguir.

```

# Carga BRONZE - Ingestão direta do Volume
# Databricks notebook source
# COMMAND -----
from pyspark.sql.functions import current_timestamp, lit

# Caminho base do Volume
volume_path = "/Volumes/mvp_eng_dados/bronze/base_dados"

# 1. Ingestão do Dataset Egressos direto do CSV no Volume
df_egressos_bronze_raw = (
    spark.read
    .format("csv")
    .option("header", "true")
    .option("inferSchema", "true")
    .load(f"{volume_path}/dataset_egressos_posgrad_erp.csv")
    .withColumn("data_ingestao", current_timestamp())
    .withColumn("arquivo_origem", lit(f"{volume_path}/dataset_egressos_posgrad_erp.csv"))
)

# 2. Ingestão do Dataset Cursos direto do CSV no Volume
df_cursos_bronze_raw = (
    spark.read
    .format("csv")
    .option("header", "true")
    .option("inferSchema", "true")
    .load(f"{volume_path}/dataset_cursos.csv")
    .withColumn("data_ingestao", current_timestamp())
    .withColumn("arquivo_origem", lit(f"{volume_path}/dataset_cursos.csv"))
)

# Criação do schema bronze se não existir
spark.sql("CREATE SCHEMA IF NOT EXISTS mvp_eng_dados.bronze")

```

Figura 4 – Tela do Databricks demonstrando a ingestão direta de dados via Camada Bronze

Também insiro aqui o código utilizado para a Camada Bronze que pode ser encontrado no notebook no link do GitHub:

https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/01_camada_bronze.ipynb.

```

# CAMADA BRONZE - Ingestão direta do Volume
# Databricks notebook source
# COMMAND -----
from pyspark.sql.functions import current_timestamp, lit

# Caminho base do Volume
volume_path = "/Volumes/mvp_eng_dados/bronze/base_dados"

# 1. Ingestão do Dataset Egressos direto do CSV no Volume
df_egressos_bronze_raw = (
    spark.read
    .format("csv")
    .option("header", "true")
    .option("inferSchema", "true")
    .load(f"{volume_path}/dataset_egressos_posgrad_erp.csv")
    .withColumn("_data_ingestao", current_timestamp())
    .withColumn("_arquivo_origem", lit(f"{volume_path}/dataset_egressos_posgrad_erp.csv"))
)

# 2. Ingestão do Dataset Cursos direto do CSV no Volume
df_cursos_bronze_raw = (
    spark.read
    .format("csv")
    .option("header", "true")
    .option("inferSchema", "true")
    .load(f"{volume_path}/dataset_cursos.csv")
    .withColumn("_data_ingestao", current_timestamp())
    .withColumn("_arquivo_origem", lit(f"{volume_path}/dataset_cursos.csv"))
)

# Criação do schema bronze se não existir
spark.sql("CREATE SCHEMA IF NOT EXISTS mvp_eng_dados.bronze")

# Gravação nas tabelas Delta Bronze (com overwriteSchema para corrigir tipos)
df_egressos_bronze_raw.write.mode("overwrite").option("overwriteSchema",
"true").saveAsTable("mvp_eng_dados.bronze.dataset_egressos_bruto")
df_cursos_bronze_raw.write.mode("overwrite").option("overwriteSchema",
"true").saveAsTable("mvp_eng_dados.bronze.dataset_cursos_bruto")

```

3. Modelagem e Catálogo de Dados (Etapa 4.3)

A estruturação da plataforma de dados foi concebida utilizando o padrão de **Arquitetura Medallion** em um ambiente **Databricks Delta Lake**. Esta abordagem garante a rastreabilidade, qualidade e governança da informação à medida que os dados brutos progridem até a disponibilização em modelos analíticos de alta performance. Para isso, foi aplicada a modelagem dimensional do tipo Estrela como detalhado a seguir.

3.1. Modelagem Dimensional (Esquema Estrela)

Esta modelagem foi aplicada a partir da camada Gold (https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/03_camada_gold.ipynb) que serviu para reorganizar os dados limpos da Silver em tabelas fato e dimensões, otimizando a execução de consultas agregadas. A imagem a seguir demonstra o notebook em que esta modelagem foi aplicada.




Figura 5 – Demonstração do notebook no Databricks em que foi aplicada a Modelagem Estrela.

Para criar o Diagrama de Relacionamento de Entidades (DRE) (Figura 6) caracterizando o modelo aplicado, em um notebook separado (https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/04_constraints_gold_output.ipynb) foi documentado os comandos DDL para criação de Primary Keys (PK) e Foreign Keys (FK) nas tabelas da camada Gold do modelo Estrela.




Figura 6 – Demonstração do notebook no Databricks em que foram aplicados os comandos DDL Constraints para Chaves PK e FK, com intuito de verificar o DRE.

Com a identificação das PKs e FKs nas tabelas gold, foi possível ver graficamente os relacionamentos como demonstrado na imagem a seguir (Figura 7).




Figura 7 – Diagrama de relacionamento de entidade (tabelas, atributos, PK e FK).

- **Tabela Fato (*fato_egressos*):** Contém a granularidade do registro individual de acompanhamento do egresso. Consolida as chaves estrangeiras (*id_egresso*, *id_curso*, *id_emplo*) e armazena métricas quantitativas e atributos categorizados:
 - Métricas numéricas: *renda_mensual_estimada*, *satisfacao_graduacao_nps*, *engajamento_alumni_score* e *meses_desde_formacao*.
 - Atributos analíticos derivados: *categoria_nps* (*Promotor*, *Neutro*, *Detrator*) e *faixa_meses_formacao* (agrupamentos temporais de pós-formação).
- **Tabelas de Dimensão:**
 - ***dim_egresso*:** Armazena o perfil demográfico do ex-aluno (*id_egresso* [PK], *idade_egresso*, *uf_residencia*, *bolsista_graduacao*).
 - ***dim_curso*:** Cataloga os dados acadêmicos e financeiros do curso (*id_curso* [PK], *nome_curso*, *area_conhecimento*, *duracao_semestres*, *mensalidade_base*, *modalidade_graduacao*).
 - ***dim_emplo*:** Dimensão categorizada para mercado de trabalho, identificada por uma *Surrogate Key* calculada via Hash MD5 (*id_emplo* [PK Hash], *nivel_cargo*, *tipo_empresa*).

3.2. Catálogo de dados

A seguir, apresento o **catálogo de dados** apenas da Camada Gold que foi gerado na plataforma Databricks. Optei por apresentar apenas a última camada, haja vista ser a camada final do pipeline e as anteriores se repetirem nessa.

A camada foi composta de nove dataframes: 1 tabela fato, 3 tabelas dimensão e 5 tabelas KPI para responderem as perguntas de negócio levantadas.

Nome	Proprietário	Criada às	Popularidade	Comment
dim_curso	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:40	✓	A tabela contém informaço...
dim_egresso	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:40	✓	A tabela contém informaço...
dim_emplo	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:40	✓	A tabela contém informaço...
fato_egressos	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:40	✓	A tabela fornece dados sobr...
kpi_conversao_tempo_bolsa	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:41	✓	A tabela fornece dados sobr...
kpi_engajabilidade_roi_curso	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:41	✓	A tabela fornece dados sobr...
kpi_engajabilidade_roi_emplo	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:41	✓	A tabela fornece dados sobr...
kpi_engajamento_alumni	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:41	✓	Esta tabela contém informaço...
kpi_perfil_profissional_uf	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:41	✓	A tabela contém informaço...
kpi_potencial_pos_graduacao	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:40	✓	A tabela contém dados sobr...

Figura 8 – Estrutura de tabelas geradas a partir do Modelo Estrela dentro do Databricks.

Catálogo de Dados da tabela *fato_egressos*:

datastacks

Q. Pesquise dados, notebooks, recentes e muito mais... CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

fato_egressos

☆

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

A tabela fornece dados sobre egressos de cursos, incluindo informações sobre formação e situações profissionais atuais. É possível utilizá-la para analisar a renda mensal estimada dos egressos, a satisfação com a graduação, o engajamento dos alumni e o tempo decorrido desde a formação. Os dados também permitem avaliar o potencial de matrícula em cursos de pós-graduação, ajudando a entender o impacto da formação no mercado de trabalho.

Q. Filtrar colunas...

Ver relacionamentos

Coluna	Tipo	Comentário
id_egresso Q= FK	int	Identificador único de cada egresso, utilizado para diferenciar os indivíduos na tabela e relacioná-los com outras informações.
id_curso Q= FK	int	Identificador do curso de formação que o egresso completou, permitindo a análise por área de estudo.
id_emplo Q= FK	string	Identificador do emprego atual do egresso, utilizado para relacionar os dados de formação com a situação profissional.
dt_ultimo_contato	timestamp	Data e hora do último contato feito com o egresso, ajudando a entender o engajamento e atualizações nas informações.
renda_mensal_estimada	decimal(10,2)	Valor estimado da renda mensal que os egressos estão recebendo, importante para análises de retorno sobre investimento em educação.
satisfacao_graduacao_nps	int	Pontuação de satisfação do egresso com a graduação, medida através do Net Promoter Score (NPS), que indica a disposição de recomendar o curso.
categoria_nps	string	Classificação do egresso conforme a categoria de NPS, que pode incluir promotores, passivos e detratores.
engajamento_alumni_score	int	Pontuação que mede o nível de engajamento dos egressos com a instituição, contribuindo para estratégias de alumni.
potencial_matricula_pos	int	Indicador que estima a probabilidade de o egresso se matricular em um curso de pós-graduação, auxiliando no planejamento de ofertas acadêmicas.
meses_desde_formacao	int	Quantidade de meses que se passaram desde a formação do egresso, relevante para análises de tempo e mercado de trabalho.
faixa_meses_formacao	string	Intervalo de meses em que a formação do egresso ocorreu, permitindo avaliar a situação dos egressos conforme a proximidade da formatura.

Catálogo de Dados da tabela *dim_curso*:

data

data

bricks

Free Edition

Q

Pesquise dados, notebooks, recentes e muito mais...

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

dim_curso

☆

Abrir em um dashboard

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

A tabela contém informações sobre cursos disponíveis. Os dados incluem o nome do curso, a área de conhecimento, a duração em semestres, a mensalidade base e a modalidade de graduação. Possíveis usos incluem análise de oferta de cursos, comparação de custos e avaliação de gama de disciplinas oferecidas.

Q

Filtrar colunas...

Coluna	Tipo	Comentário
id_curso PK	int	Identificador único do curso, utilizado para distinguir cada curso na tabela.
nome_curso	string	O nome completo do curso, útil para identificar e descrever o conteúdo educacional oferecido.
area_conhecimento	string	Refere-se à área de estudo relacionada ao curso, permitindo a categorização dos cursos por disciplina.
duracao_semestres	int	Indica a duração do curso em semestres, o que ajuda na avaliação do compromisso de tempo necessário para a conclusão.
mensalidade_base	decimal(10,2)	Representa o valor mensal a ser pago para cursar, fundamental para análise de custos e viabilidade financeira.
modalidade_graduacao	string	Descreve a forma de formação acadêmica oferecida pelo curso, importante para entender as opções disponíveis aos alunos.

Catálogo de Dados da tabela *dim_egressos*:

databricks
Free Edition

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

dim_egresso

☆

Abrir em um da

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

A tabela contém informações sobre egressos, incluindo dados demográficos e de residência. Possíveis usos incluem análise de perfis de egressos, avaliação de programas de bolsa e estudo de deslocamento geográfico após a graduação.

Coluna	Tipo	Comentário	
id_egresso PK	int	Identificador único associado a cada egresso, permitindo rastrear informações específicas sobre indivíduos ao longo do tempo.	
idade_egresso	int	Indica a idade do egresso no momento da coleta dos dados, possibilitando análises demográficas e de faixa etária.	
uf_residencia	string	Representa a unidade federativa onde o egresso reside atualmente, essencial para estudos sobre distribuição geográfica e mobilidade.	
bolsista_graduacao	int	Demonstrates whether the graduate received a scholarship during their studies, useful for evaluating the impact of financial aid programs.	

Catálogo de Dados da tabela *dim_emprego*:

databricks
Free Edition

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

dim_emprego

☆

Abrir em um da

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

A tabela contém informações sobre empregos, incluindo detalhes como o nível do cargo e o tipo da empresa. Pode ser utilizada para análises relacionadas à estrutura de cargos, comparação entre tipos de empresas e para entender a distribuição de funções na organização.

Coluna	Tipo	Comentário	
id_emprego PK	string	Identificador único de cada emprego na tabela, permitindo rastrear informações específicas relacionadas a uma posição de trabalho.	
nivel_cargo	string	Representa o nível hierárquico do cargo, proporcionando uma visão sobre a estrutura organizacional e a distribuição de responsabilidades.	
tipo_empresa	string	Classifica o tipo de empresa, utilizado para análises comparativas entre diferentes setores e modelos de negócios.	

Catálogo de Dados da tabela *kpi_conversao_tempo_bolsa*:

databricks

Free Edition

Pesquisar dados, notebooks, recentes e muito mais...CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

kpi_conversao_tempo_bolsa

⌵ ☆

⋮

Abriu em um dashboard

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

A tabela fornece dados sobre o desempenho de bolsistas ao longo do tempo de formação. Os possíveis usos incluem a análise da taxa de egressos graduados e a avaliação do potencial pós-formação. Ela registra informações como as diferentes faixas de meses de formação, o número de bolsistas que se graduaram, o total de egressos e o total de potenciais formados, além da taxa de potencial pós-formação em porcentagem.

Filtrar colunas...

Coluna	Tipo	Comentário	
faixa_meses_formacao	string	Representa as diferentes faixas de meses que os bolsistas levaram para completar sua formação, permitindo a análise do tempo de conclusão.	
bolsista_graduacao	int	Indica o número de bolsistas que conseguiram se graduar dentro do período analisado.	
total_egressos	bigint	Refere-se ao total de egressos que saíram do programa, independentemente de terem se graduado ou não.	
total_potencial_pos	bigint	Quantidade total de egressos considerados como potenciais formados, que podem ter oportunidades após a formação.	
taxa_potencial_pos_pct	double	Expressa a taxa em porcentagem que representa a proporção do total de egressos que foram considerados como potenciais formados.	

Catálogo de Dados da tabela `kpi_employabilidade_roi_curso`:

data

bricks

free edition

Q

Pesquise dados, notebooks, recentes e muito mais...

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

kpi_employability_roi_course

☆

Abrir em um dashboard

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

A tabela fornece dados sobre a empregabilidade relacionada a cursos e seus impactos financeiros. Os principais elementos a serem analisados incluem a renda média dos egressos, mensalidades dos cursos e a relação entre ROI e rendimento. Possíveis usos incluem a avaliação da viabilidade de cursos, comparação entre modalidades de graduação, e análise das taxas de empregabilidade em diferentes tipos de empresas.

Q

Filtrar colunas...

Coluna	Tipo	Comentário	
nome_curso	string	O nome completo do curso, útil para identificar e descrever o conteúdo educacional oferecido.	
modalidade_graduacao	string	Indica o formato em que o curso é oferecido, como presencial ou online, importante para entender a acessibilidade e as preferências dos alunos.	
nivel_cargo	string	Refere-se à posição ou nível profissional que os egressos ocupam após a conclusão do curso, ajudando na análise da trajetória de carreira dos formados.	
tipo_empresa	string	Representa o setor ou tipo de empresa onde os egressos estão empregados, proporcionando insights sobre a empregabilidade e o mercado de trabalho.	
mensalidade_base	decimal(10,2)	Representa o valor mensal a ser pago para cursar, fundamental para análise de custos e viabilidade financeira.	
qtd_egressos	bigint	Indica a quantidade de alunos que se formaram no curso, um dado relevante para avaliar a popularidade e o alcance do programa educacional.	
renda_media	decimal(11,2)	O valor médio que os egressos ganham após a graduação, essencial para medir o retorno sobre o investimento em educação.	
razao_roi_renda_mensalidade	decimal(14,2)	Representa a relação entre o retorno sobre o investimento e o valor da mensalidade do curso, proporcionando uma métrica para avaliar a eficácia financeira do curso.	

Catálogo de Dados da tabela *kpi_nps_engajamento_alumni*:

databricks

Free Edition

Pesquise dados, notebooks, recentes e muito mais...

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

kpi_nps_engajamento_alumni

☆

Abriu em uma nova aba

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

Esta tabela contém informações sobre o engajamento de alumni e suas percepções sobre a satisfação com a graduação. É útil para analisar a categoria de satisfação dos ex-alunos, a média de engajamento e a taxa de potencial de pós-graduação. As informações podem ser usadas para entender melhor as experiências dos graduados e informar iniciativas de engajamento.

Filtrar colunas...

Coluna	Tipo	Comentário	
categoria_nps	string	Representa a categoria de Net Promoter Score (NPS), utilizada para classificar o nível de recomendação dos alumni em relação à graduação.	
satisfacao_graduacao_nps	int	Indica o nível de satisfação dos ex-alunos com a graduação, medido em uma escala numérica.	
modalidade_graduacao	string	Refere-se ao tipo de graduação que o alumni completou, como bacharelado, tecnólogo ou outro.	
total_egressos	bigint	O total de alumni que se formaram e cujas opiniões sobre a graduação estão sendo consideradas.	
media_engajamento_alumni	double	Calcula a média do nível de engajamento dos alumni, refletindo sua participação e interação com a instituição após a graduação.	
total_potencial_pos	bigint	Número total de alumni que possuem potencial para continuar seus estudos em pós-graduação.	
taxa_potencial_pos_pct	double	Representa a porcentagem do total de alumni que são considerados potenciais candidatos a programas de pós-graduação.	

Catálogo de Dados da tabela *kpi_perfil_profissional_uf*:

databricks

PREMIUM

Q Pesquise dados, notebooks, recentes e muito mais...

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

kpi_perfil_profissional_uf

⌵ ☆

⋮

Abriu em um novo navegador

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade


Descrição

A tabela contém informações sobre perfis profissionais por unidade federativa (UF). Os dados incluem área de atuação, nível do cargo, tipo de empresa, quantidade de egressos e informações econômicas como renda média e taxa potencial de posicionamento percentual. Possíveis usos incluem análises de mercado de trabalho em diferentes regiões, avaliação de oportunidades de formação e entender as dinâmicas salariais em diversas áreas.

Q Filtrar colunas...

Coluna	Tipo	Comentário	
uf_residencia	string	Representa a unidade federativa onde o profissional reside, permitindo análises regionais sobre o mercado de trabalho.	
area_atuacao	string	Indica a área de atuação profissional, ajudando a compreender as diferentes oportunidades de emprego disponíveis em cada setor.	
nivel_cargo	string	Refere-se ao nível hierárquico do cargo ocupado pelo profissional, essencial para entender a distribuição e evolução de carreiras nas diversas áreas.	
tipo_empresa	string	Classifica o tipo de empresa onde o profissional atua, fornecendo insights sobre o ambiente de trabalho e oportunidades de emprego em diferentes setores.	
qtd_egressos	bigint	Representa a quantidade de egressos, ou seja, profissionais formados que atuam na área, permitindo avaliar a saturação do mercado.	
total_potencial_pos	bigint	Indica o total de posições potenciais disponíveis no mercado para a área de atuação, ajudando a entender as oportunidades de emprego.	
renda_media	decimal(11,2)	Apresenta a renda média dos profissionais na área, facilitando análises sobre a remuneração e condições econômicas em diferentes setores.	
media_meses_formado	double	Refere-se à média de meses desde a formação dos profissionais, oferecendo uma perspectiva sobre o tempo de ingresso no mercado de trabalho.	
taxa_potencial_pos_pct	double	Indica a taxa potencial de posicionamento percentual dos profissionais na área, útil para avaliar a competição e as chances de colocação no mercado.	

Catálogo de Dados da tabela *kpi_potencial_pos_graduacao*:



Explorador de Catálogos > mvp_eng_dados > gold >

kpi_potencial_pos_graduacao ⌵ ☆

Visão geral Dados de exemplo Detalhes Permissões Políticas Histórico Linhagem Insights Qualidade

Descrição ✎

A tabela contém dados sobre cursos de pós-graduação e seu potencial. Inclui informações sobre o nome do curso, área de conhecimento, modalidade de graduação, total de egressos e o potencial estimado para pós-graduação. Além disso, apresenta métricas como a média do NPS (Net Promoter Score) e a taxa percentual de potencial para pós-graduação. Possíveis usos incluem análise de demanda por cursos de pós-graduação e avaliação do desempenho de diferentes áreas do conhecimento.

🔍 Filtrar colunas...

Coluna	Tipo	Comentário
nome_curso	string	O nome completo do curso, útil para identificar e descrever o conteúdo educacional oferecido.
area_conhecimento	string	Refere-se à área de estudo relacionada ao curso, permitindo a categorização dos cursos por disciplina.
modalidade_graduacao	string	Indica o tipo de graduação oferecido, o que pode incluir opções como presencial, online ou híbrido.
total_egressos	bigint	Número total de alunos que concluíram o curso, importante para medir o impacto e a popularidade do mesmo.
total_potencial_pos	bigint	Quantidade estimada de alunos que poderiam ingressar em cursos de pós-graduação, refletindo o potencial de demanda por essas opções.
media_nps	double	A média do Net Promoter Score, que mensura a lealdade dos alunos e sua disposição em recomendar o curso a outras pessoas.
taxa_potencial_pos_pct	double	Representa a taxa percentual do potencial estimado para pós-graduação, fornecendo uma visão clara sobre a viabilidade de novos ingressantes.

4. Pipeline de Dados (Etapa 4.4)

O processo de pipeline ETL foi feito em uma Estrutura Medalhão e cada uma das camadas foi colocada em um notebook diferente, que está sendo descrito a seguir, com seus respectivos links de acesso do GitHub.




Figura 9 – Demonstração das camadas criadas em notebooks separados.

4.1. Arquitetura em Camadas (Pipeline de Dados)

- **Camada Bronze (Raw Ingestion)**
(https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/01_camada_bronze.ipynb): Atua como repositório de persistência dos dados brutos consumidos diretamente das fontes originais (arquivos CSV armazenados em Volumes). Os dados das tabelas *bronze.dataset_egressos_bruto* e *bronze.dataset_cursos_bruto* são gravados em formato Delta no modo *overwrite*, recebendo atributos de auditoria como *_data_ingestao* e *_arquivo_origem* para assegurar total linhagem (*lineage*).
- **Camada Silver (Cleansed & Refined)**
(https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/02_camada_silver.ipynb): Responsável pela higienização, tipagem estrita e aplicação de regras de qualidade e sanidade de dados.
 - **Sanitização de limites:** Valores de *idade_egresso* fora do intervalo biológico de 16 a 100 anos e *renda_mensal_estimada* menores que zero são invalidados (convertidos para NULL).
 - **Tratamento de texto e deduplicação:** Strings foram padronizadas via remoção de espaços sobressalentes (TRIM) e conversão para maiúsculas (UPPER). As duplicatas foram eliminadas com base na unicidade dos registros de negócio.
 - **Atualização idempotente:** As tabelas sanitizadas (*silver.dataset_egressos* e *silver.dataset_cursos*) garantem integridade estrutural para a camada analítica.
- **Camada Gold (Curated & Data Marts)**
(https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/03_camada_gold.ipynb): Camada final voltada ao consumo analítico e *Business Intelligence*, estruturada sobre um **Modelo Dimensional em Esquema Estrela (Star Schema)** no banco *mvp_eng_dados.gold*.

As camadas foram integradas por meio de código como mostrado a seguir:

```
1: Camada Bronze - Processamento Completo

# CAMADA BRONZE - Ingestão direta do Volume
# Databricks notebook source
# COMMAND -----
from pyspark.sql.functions import current_timestamp, lit

# Caminho base do Volume
volume_path = "/Volumes/mvp_eng_dados/bronze/base_dados"

# 1. Ingestão do Dataset Egressos direto do CSV no Volume
df_egressos_bronze_raw = (
    spark.read
        .format("csv")
        .option("header", "true")
        .option("inferSchema", "true")
        .load(f"{volume_path}/dataset_egressos_posgrad_erp.csv")
        .withColumn("_data_ingestao", current_timestamp())
        .withColumn("_arquivo_origem", lit(f"{volume_path}/dataset_egressos_posgrad_erp.csv"))
)
```

```
15 de set. de 2026 (22s) 1: Camada Silver - Processamento Completo

# CAMADA SILVER
# Databricks notebook source
# COMMAND -----
from pyspark.sql.functions import col, to_timestamp, trim, upper, when, current_timestamp, hash, concat_ws, abs
from delta.tables import DeltaTable

# Garante criação do schema Silver se não existir
spark.sql("CREATE SCHEMA IF NOT EXISTS mvp_eng_dados.silver")

# =====
# 1. TRATAMENTO DA TABELA FATO EGRESSOS
# =====

# 1. Leitura da tabela Bronze
df_bronze_egressos = (
    spark.read.table("mvp_eng_dados.bronze.dataset_egressos_bruto")
    # Remove duplicatas por atributos de negócio (mantém apenas um registro por combinação única)
    .dropDuplicates([
        "id_curso", "dt_ultimo_contato", "uf_residencia",
        "meses_desde_formacao", "idade_egresso", "nivel_cargo",
        "renda_mensal_estimada", "area_atuacao", "modalidade_graduacao",
        "tipo_empresa", "satisfacao_graduacao_nps", "engajamento_alumni_score",
        "bolsista_graduacao", "potencial_matricula_pos"
    ])
)
```

```
Há 2 minutos (1min) 1: Camada Gold - Processamento Completo

# CAMADA GOLD
# Databricks notebook source
# COMMAND -----
# 1. IMPORTS E CONFIGURAÇÃO INICIAL
from pyspark.sql.functions import col, count, sum, avg, round, md5, concat_ws, when

# Garante a criação do schema gold
spark.sql("CREATE SCHEMA IF NOT EXISTS mvp_eng_dados.gold")

# Leitura das fontes tratadas na camada Silver
df_silver_egressos = spark.read.table("mvp_eng_dados.silver.dataset_egressos")
df_silver_cursos = spark.read.table("mvp_eng_dados.silver.dataset_cursos")

# COMMAND -----
# 2. MODELAGEM DIMENSIONAL (ESQUEMA ESTRELA)

# 2.1 Dimensão: Egresso
```

Vale também ressaltar que todas as tabelas geradas em cada camada foram salvas (persistidas) na plataforma Databricks em nuvem, como mostra a imagem a seguir.




Figura 10 – Tabelas das camadas medalhão persistidas no Databricks

4.2. Data Marts de KPIs e Otimização Física

Para atender de forma direta e rápida às questões de negócio da instituição, foram construídas dataframes agregados de segundo nível na Camada Gold (*kpi_potencial_pos_graduacao*, *kpi_conversao_tempo_bolsa*, *kpi_employabilidade_roi_curso*, *kpi_nps_engajamento_alumni* e *kpi_perfil_profissional_uf*).

Como estratégia de otimização de leitura e diminuição de *data scanning*, foi aplicado o recurso de **Z-Ordering** nas tabelas físicas do Delta Lake. Esta arquitetura garante que a plataforma atue como uma Fonte Única da Verdade (SSOT), aliando governança no consumo bruto e performance no processamento analítico.

É possível visualizar o código aplicado para isso na camada gold acessando o link no GitHub:

https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/03_camada_gold.ipynb.

5. Qualidade de Dados (Etapa 4.5)

Apresento a seguir a análise técnica detalhada dos problemas identificados no pipeline de ingestão bruta (Camada *Bronze*) e a explicação completa de como cada inconsistência foi resolvida durante o processamento para a Camada *Silver* (*mvp_eng_dados.silver*).

O objetivo central desta etapa do pipeline ETL foi garantir a qualidade, integridade relacional, conformidade do schema (*schema enforcement*) e sanidade das regras de negócio antes que os dados fossem disponibilizados para consumo analítico.

5.1. Visão Geral do Pipeline na Camada Silver

A Camada *Silver* atua como a camada de limpeza, padronização e enriquecimento. No script PySpark (https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/02_camada_silver.ipynb), foram processadas duas entidades principais originadas do catálogo Delta:

- **Fato Egressos** (mvp_eng_dados.bronze.dataset_egressos_bruto > mvp_eng_dados.silver.dataset_egressos).
- **Dimensão Cursos** (mvp_eng_dados.bronze.dataset_cursos_bruto > mvp_eng_dados.silver.dataset_cursos).

5.2. Problemas Detectados e Soluções Aplicadas no Dataset de Egressos

A. Registros Duplicados na Origem Bruta

- **Problema Detectado:** Existência de linhas totalmente duplicadas ou reincidentes na camada *Bronze*, o que geraria distorções em métricas agregadas na camada analítica.
- **Resolução e Transformação:** Foi aplicada a função `.dropDuplicates()` considerando o conjunto explícito de atributos de negócio (`id_curso`, `dt_ultimo_contato`, `uf_residencia`, `meses_desde_formacao`, `idade_egresso`, `nivel_cargo`, `renda_mensal_estimada`, `area_atuacao`, `modalidade_graduacao`, `tipo_empresa`, `satisfacao_graduacao_nps`, `engajamento_alumni_score`, `bolsista_graduacao` e `potencial_matricula_pos`). Com isso, apenas um registro único por perfil funcional é mantido.

B. Ausência e Incompatibilidade de Chaves Primárias

- **Problema Detectado:** Registros com a chave identificadora do egresso (`id_egresso`) nula ou sem tipagem de inteiro, comprometendo o relacionamento relacional.
- **Resolução e Transformação:**
 - Filtragem estrita dos registros sem identificador válido usando `.filter(col("id_egresso").isNotNull())`.
 - *Casting* explícito das chaves `id_egresso` e `id_curso` para o tipo inteiro (`.cast("int")`).

C. Inconsistência na Formatação de Strings e Espaços Sobressalentes

- **Problema Detectado:** Presença de caracteres em caixa alta e baixa misturados, além de espaços em branco antes ou depois de palavras nos campos de texto (`uf_residencia`, `nivel_cargo`, `area_atuacao`, `modalidade_graduacao`, `tipo_empresa`).
- **Resolução e Transformação:** Aplicação combinada das funções de higienização de texto `upper(trim(col(...)))` para remover espaços excedentes e padronizar todas as cadeias de caracteres em caixa alta.

D. Tipagem Inadequada de Datas e Métricas

- **Problema Detectado:** Datas de contato mantidas em formato *string* ou formato não legível por ferramentas de Business Intelligence.
- **Resolução e Transformação:** Conversão do campo `dt_ultimo_contato` para o tipo temporal estruturado utilizando `to_timestamp()`.

E. Violação de Limites Físicos/Biológicos e Valores Numéricos Fora de Regra

- **Problema Detectado:** Presença de ruídos ou *outliers* como idades negativas ou irreais (ex.: menor que 16 anos ou maior que 100 anos), valores negativos para tempo de formação (`meses_desde_formacao`) e renda mensal estimada negativa (`renda_mensal_estimada`).
- **Resolução e Transformação:** Aplicação de regras condicionais `when(...).otherwise(None)` para higienização e saneamento de dados:
 - `meses_desde_formacao`: se ≥ 0 , mantém o valor convertido em int; caso contrário, atribui None (nulo).
 - `idade_egresso`: validado no intervalo pragmático de 16 a 100 anos. Valores fora do intervalo são convertidos para None.
 - `renda_mensal_estimada`: se ≥ 0 , converte para a precisão financeira `decimal(10,2)`; valores inconsistentes se tornam None.

F. Escalas de Avaliação e Indicadores Fora do Intervalo Válido

- **Problema Detectado:** Pontuações da pesquisa NPS (`satisfacao_graduacao_nps`) contendo valores fora do padrão de 0 a 10.
- **Resolução e Transformação:** Validação condicional `when((col("satisfacao_graduacao_nps") >= 0) & (col("satisfacao_graduacao_nps") <= 10))`, convertendo os válidos para int e saneando pontuações fora da faixa para None. Outras variáveis inteiras (`engajamento_alumni_score`, `bolsista_graduacao`, `potencial_matricula_pos`) também receberam *casting* para int.

G. Ausência de Atributo Analítico Direto sobre Situação Profissional

- **Problema Detectado:** Dificuldade na geração de relatórios diretos sobre taxa de empregabilidade sem a necessidade de avaliar strings da coluna `tipo_empresa` a todo momento.
- **Resolução e Transformação:** Engenharia de atributos (*Feature Engineering*) criando a coluna flag `is_empregado`, atribuindo 0 caso o tipo de empresa padronizado seja "DESEMPREGADO", e 1 para qualquer outro tipo.

5.3. Problemas Detectados e Soluções Aplicadas no Dataset de Cursos

A. Registros sem Identificador e Duplicidade de Chave Primária

- **Problema Detectado:** Presença de registros sem `id_curso` e cursos duplicados na base cadastral.
- **Resolução e Transformação:**
 - Descarte de registros nulos com `.filter(col("id_curso").isNull())`.

- Remoção de duplicatas focada estritamente na chave primária do curso com `.dropDuplicates(["id_curso"])`.
- *Casting* de `id_curso` para `int`.

B. Despadronização dos Nomes e Áreas do Conhecimento

- **Problema Detectado:** Textos dos cursos e áreas de conhecimento com variações de caixa e espaços antes/depois.
- **Resolução e Transformação:** Sanitização com `upper(trim(col("nome_curso")))` e `upper(trim(col("area_conhecimento")))`.

C. Valores Negativos em Duração e Mensalidade

- **Problema Detectado:** Cursos configurados com semestres zerados ou negativos, além de valores de mensalidade base incoerentes.
- **Resolução e Transformação:**
 - `duracao_semestres`: validado para aceitar apenas valores estritamente maiores que zero (> 0), convertidos em `int`.
 - `mensalidade_base`: validado para valores maiores ou iguais a zero (≥ 0), convertidos em `decimal(10,2)`.

5.4. Rastreabilidade, Governança e Estratégia de Carga no Delta Lake

Para atender aos padrões de auditoria e manter o ecossistema Delta Lake consistente, o pipeline implementou duas táticas de gravação e governança:

- **Rastreabilidade de Ingestão (Auditoria):**
 - Em ambas as tabelas (`dataset_egressos` e `dataset_cursos`), foi adicionada a coluna de metadados `_data_processamento_silver` contendo o carimbo de data/hora da execução do ETL (`current_timestamp()`).
- **Estratégias de Persistência Diferenciadas:**
 - **Tabela Fato Egressos:** Utiliza estratégia de carga total com substituição controlada do schema (`write.format("delta").mode("overwrite").option("overwriteSchema", "true")`). Isso assegura que o dataset reconstruído reflita totalmente as regras de saneamento atualizadas.
 - **Tabela Dimensão Cursos:** Utiliza carga idempotente baseada no padrão **MERGE (UPSERT)** via `DeltaTable.merge()`. A condição de cruzamento `target.id_curso = source.id_curso` executa a atualização de registros existentes (`whenMatchedUpdateAll()`) e a inserção de novos cursos (`whenNotMatchedInsertAll()`), evitando qualquer duplicação na ingestão incremental.

Com essas transformações, a camada *Silver* atinge um estado de alta confiabilidade, estruturada sobre um schema bem definido e pronta para alimentar agregações e modelos analíticos na camada *Gold*.

6. Análise de Dados (Etapa 4.5)

Após a aplicação das camadas medalhão (um notebook para cada camada), também foi criado um notebook somente para a análise de dados no intuito de se responder às perguntas de negócio. Ele pode ser encontrado de forma completa no GitHub no link: https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/05_analise_dados_output.ipynb. A seguir, também apresento todo o resultado descrito.


A análise realizada responde às 11 perguntas que foram divididas em 4 categorias de conhecimento, mas que estão interligadas por um único problema central como apresentado no início desse relatório: **a desconexão entre a gestão do ciclo de vida do (LTV – Lifetime Value) e a previsibilidade de receita na conversão de egressos para a Pós-Graduação.**

A. Timing e Propensão: Potencial de Conversão e Captação de Pós-Graduação (Setores: Marketing e Financeiro)

1. Qual é a taxa de conversão (potencial_matricula_pos) por curso (nome_curso) e por área do conhecimento?

Análise Técnica: Consultei o Data Mart gold.kpi_potencial_pos_graduacao para calcular a proporção de egressos com interesse em pós-graduação sobre o total por curso e área.

Data Mart Utilizado: gold.kpi_potencial_pos_graduacao



The screenshot shows a Jupyter Notebook interface with a SQL query and its results. The query is as follows:

```
%sql
-- COMMAND -----
-- DBTITLE 1, 1. Taxa de Conversão por Curso e Área do Conhecimento
SELECT
    nome_curso,
    area_conhecimento,
    SUM(total_egressos) AS total_egressos,
    SUM(total_potencial_pos) AS total_potencial_pos,
    ROUND((SUM(total_potencial_pos) / SUM(total_egressos)) * 100, 2) AS taxa_conversao_pct
FROM gold.kpi_potencial_pos_graduacao
GROUP BY nome_curso, area_conhecimento
ORDER BY taxa_conversao_pct DESC;
```

The results are displayed in a table with 6 rows and 6 columns. The columns are: nome_curso, area_conhecimento, total_egressos, total_potencial_pos, and taxa_conversao_pct. The table is sorted by taxa_conversao_pct in descending order.

	nome_curso	area_conhecimento	total_egressos	total_potencial_pos	1.2 taxa_conversao_pct
1	PEDAGOGIA	HUMANAS	574	106	18.47
2	PSICOLOGIA	HUMANAS	506	93	18.38
3	DIREITO	HUMANAS	584	101	17.29
4	ADMINISTRAÇÃO	HUMANAS	565	94	16.64
5	MEDICINA VETERINÁRIA	BIOLÓGICAS	592	95	16.05
6	BIOMEDICINA	BIOLÓGICAS	576	87	15.1

At the bottom of the table, it indicates 16 linhas and 18,529s de runtime. A note at the bottom states: "Este resultado é armazenado como _sqlidf e pode ser usado em outras células Python e SQL."

Análise dos resultados:

Com base nos dados apresentados no notebook (Taxa de Conversão por Curso e Área do Conhecimento), apresento a análise dos resultados.

Destaques de Desempenho:

- **Humanas Lidera o Ranking:** Todos os 4 primeiros colocados pertencem à área de Humanas. Pedagogia ocupa o primeiro lugar com a maior taxa de conversão (18,47%), seguida por Psicologia (18,38%), Direito (17,29%) e Administração (16,64%).
- **Biológicas Apresenta Desempenho Consistente:** Os cursos da área de Biológicas ocupam do 5º ao 8º lugar, mantendo uma taxa de conversão intermediária entre 13,48% (Nutrição) e 16,05% (Medicina Veterinária, acompanhada de Biomedicina com 15,10% e Enfermagem com 14,59%).
- **Tecnologia e Exatas com Baixa Proporção:** Os cursos das áreas de Tecnologia e Exatas apresentaram as menores taxas de conversão (todas abaixo de 8%). Matemática Aplicada (5,83%) e Sistemas de Informação (5,67%) registraram os menores índices.

Insights para Estratégia de Negócio:

- **Volume vs. Proporção:** Cursos de Tecnologia como Ciência da Computação (957 egressos) e ADS (913 egressos) possuem as maiores bases de egressos, porém apresentam baixa intenção proporcional de pós-graduação (~7,31% a 7,45%). O foco comercial para estes cursos deve ser em ofertas mais alinhadas ao mercado de trabalho (como certificações ou MBAs curtos) para tentar elevar o interesse.
- **Foco de Aquisição em Humanas e Saúde:** Campanhas diretas de captação para programas de pós-graduação lato/stricto sensu têm maior eficiência e ROI quando direcionadas para egressos de Humanas e Biológicas, onde entre 13,48% e 18,47% dos alunos demonstram interesse ativo em continuar os estudos.

2. Qual o tempo ideal após a graduação (meses_desde_formacao) em que os egressos demonstram maior intenção de matrícula?

Análise Técnica: Agrupei a intenção de matrícula pelas faixas de meses desde a formação (faixa_meses_formacao) já pré-calculadas na camada Gold para identificar a janela temporal de ouro para campanhas de captação.

Data Mart Utilizado: gold.kpi_conversao_tempo_bolsa

Há 4 dias (3s) 9

```
%sql
-- COMMAND -----
-- DBTITLE 1, 2. Janela Temporal Ideal de Conversão para Pós-Graduação
SELECT
    faixa_meses_formacao,
    SUM(total_egressos) AS total_egressos,
    SUM(total_potencial_pos) AS total_potencial_pos,
    ROUND((SUM(total_potencial_pos) / SUM(total_egressos)) * 100, 2) AS taxa_intencao_pct
FROM gold.kpi_conversao_tempo_bolsa
GROUP BY faixa_meses_formacao
ORDER BY taxa_intencao_pct DESC;
```

> [Ver desempenho \(1\)](#) ✓ Verificado para melhorias

	1.1 faixa_meses_formacao	1.2 total_egressos	1.3 total_potencial_pos	1.2 taxa_intencao_pct
1	Mais de 36 meses	7762	898	11.57
2	25 a 36 meses	1149	104	9.05
3	13 a 24 meses	1183	91	7.69
4	0 a 12 meses	633	43	6.79

4 linhas 2,827s de runtime Atualizada há Há 4 dias

Este resultado é armazenado como _sqlidf e pode ser usado em outras células Python e SQL.

Análise dos resultados:

Com base no retorno da consulta SQL (Janela Temporal Ideal de Conversão para Pós-Graduação) no notebook, apresento a análise detalhada dos resultados.

Destaques do Desempenho por Faixa de Tempo:

- Liderança Isolada (Mais de 36 meses): A maior propensão à pós-graduação está entre os egressos formados há mais de 3 anos, atingindo a maior taxa de intenção (11,57%) e concentrando a imensa maioria dos potenciais inscritos (898 de 1.136 alunos, equivalente a ~79% do total).
- Maturação Gradual da Intenção: Quanto mais tempo se passa desde a graduação, maior é a taxa de intenção de matrícula:
 - 0 a 12 meses: 6,79% de intenção
 - 13 a 24 meses: 7,69% de intenção
 - 25 a 36 meses: 9,05% de intenção
 - Mais de 36 meses: 11,57% de intenção

Insights e Recomendações Estratégicas:

- O Momento da Decisão: Recém-formados (0 a 12 meses) possuem a menor taxa de conversão (6,79%), possivelmente por focarem no ingresso imediato no mercado de trabalho ou por restrições financeiras. O interesse se consolida e cresce significativamente após o 2º ano de formado.
- Estratégia de Réguas de Relacionamento (Nutrição):
 - Anos 1 e 2: Manter engajamento contínuo com conteúdos leves, networking, eventos da comunidade alumni e ofertas de cursos curtos de extensão.
 - Ano 3 em diante (Janela de Ouro): Intensificar campanhas comerciais diretas de captação para pós-graduação (lato e stricto sensu), aproveitando a fase em que o profissional busca especialização ou reposicionamento na carreira.

3. Ex-bolsistas de graduação (bolsista_graduacao) possuem maior probabilidade de continuar os estudos em comparação aos não bolsistas?

Análise Técnica: Consultei diretamente o Data Mart gold.kpi_conversao_tempo_bolsa, agrupando os egressos pela dimensão bolsista_graduacao para calcular a taxa de propensão à pós-graduação entre alunos bolsistas e não bolsistas, sem necessidade de JOIN, pois a coluna já está disponível na tabela.

Data Mart Utilizado: gold.kpi_conversao_tempo_bolsa

Há 4 dias (2s) 12

```
%sql
-- COMMAND -----
-- DBTITLE 1, 3. Propensão à Pós-Graduação: Bolsistas vs. Não Bolsistas
SELECT
    bolsista_graduacao,
    SUM(total_egressos) AS total_egressos,
    SUM(total_potencial_pos) AS total_potencial_pos,
    ROUND((SUM(total_potencial_pos) / SUM(total_egressos)) * 100, 2) AS taxa_intencao_pct
FROM gold.kpi_conversao_tempo_bolsa
GROUP BY bolsista_graduacao
ORDER BY taxa_intencao_pct DESC;
```

> [Ver desempenho \(1\)](#) ✓ Verificado para melhorias

	bolsista_graduacao	total_egressos	total_potencial_pos	taxa_intencao_pct
1	0	5069	552	10.89
2	1	5658	584	10.32

2 linhas 1,961s de runtime Atualizada há 4 dias

Este resultado é armazenado como _sqlidf e pode ser usado em outras células Python e SQL.

Análise de resultados:

Com base nos resultados exibidos no notebook (Propensão à Pós-Graduação: Bolsistas vs. Não Bolsistas), apresento a análise detalhada dos dados.

Destaques do Desempenho:

- Taxas de Propensão Praticamente Equivalentes: Não há diferença expressiva na intenção de matrícula entre os dois grupos.
 - Não Bolsistas (0): 10,89% de taxa de intenção.
 - Bolsistas (1): 10,32% de taxa de intenção.
- Volume Absoluto: Dos 1.136 potenciais alunos mapeados:
 - 584 são ex-bolsistas (de um total de 5.658 egressos bolsistas).
 - 552 são não bolsistas (de um total de 5.069 egressos não bolsistas).

Insights e Recomendações Estratégicas:


- Mito Desmistificado: Ter sido bolsista durante a graduação não aumenta a probabilidade de continuar os estudos na pós-graduação em relação a quem pagou integralmente.
- Incentivos Financeiros: A leve diferença para baixo nos bolsistas (10,32% vs 10,89%) pode indicar maior sensibilidade a preço ou restrição orçamentária no pós-formação.
- Ação de Marketing/Vendas: Campanhas direcionadas ao público de ex-bolsistas devem priorizar ofertas com descontos progressivos, bolsas ex-aluno ou opções facilitadas de parcelamento para converter essa base expressiva em matrículas efetivas.

B. Capacidade Financeira: Empregabilidade e Perfil Socioeconômico (Setores: Marketing e Financeiro)

4. Qual é a renda média e a distribuição de cargos (nivel_cargo) por curso e por modalidade (modalidade_graduacao)?

Análise Técnica: Interseccionei os dados de curso, modalidade e emprego (gold.dim_emprego) para segmentar o avanço de carreira dos egressos e a sua respectiva renda.

Data Mart Utilizado: gold.kpi_employability_roi_course



The screenshot shows a SQL query editor with a query that calculates the weighted average salary and career level for each course and modality. The results are displayed in a table with 7 rows and 6 columns.

```
%sql
-- COMMAND -----
-- DBTITLE 1, 4. Renda Média Ponderada e Nível de Cargo por Curso e Modalidade
SELECT
    nome_curso,
    modalidade_graduacao,
    nivel_cargo,
    SUM(qtd_egressos) AS total_egressos,
    ROUND(SUM(qtd_egressos * renda_media) / SUM(qtd_egressos), 2) AS renda_media_ponderada
FROM gold.kpi_employability_roi_course
GROUP BY nome_curso, modalidade_graduacao, nivel_cargo
ORDER BY nome_curso, modalidade_graduacao, renda_media_ponderada DESC;
```

	nome_curso	modalidade_graduacao	nivel_cargo	total_egressos	renda_media_ponderada
1	ADMINISTRAÇÃO	EAD	GESTÃO	35	15109.91
2	ADMINISTRAÇÃO	EAD	SÊNIOR	55	10253.49
3	ADMINISTRAÇÃO	EAD	PLENO	38	6719.31
4	ADMINISTRAÇÃO	EAD	JÚNIOR	33	6621.65
5	ADMINISTRAÇÃO	EAD	SEM VÍNCULO	14	853.50
6	ADMINISTRAÇÃO	HÍBRIDO	GESTÃO	16	13731.60
7	ADMINISTRAÇÃO	HÍBRIDO	SÊNIOR	23	11805.56

240 linhas | 3,178s de runtime

Atualizada há 4 dias

Este resultado é armazenado como _sqlidf e pode ser usado em outras células Python e SQL.

Análise de resultados:

Com base nos resultados da consulta SQL (Renda Média Ponderada e Nível de Cargo por Curso e Modalidade) apresentados no notebook, segue a análise detalhada dos dados.

Destaques do Desempenho por Cargo e Modalidade:

- **Progressão Salarial Nítida:** Em todas as modalidades e cursos, a remuneração acompanha diretamente a senioridade do cargo, atingindo o pico na posição de Gestão (média de R\$ 12.500,00 a R\$ 16.200,00) e o valor inicial no nível Júnior (R\$ 5.600,00 a R\$ 7.600,00).
- **Paridade de Renda entre EAD, Híbrido e Presencial:** A modalidade de ensino não apresenta penalização na renda dos formados. Em Análise e Desenvolvimento de Sistemas (ADS), por exemplo, a posição de Gestão no Híbrido lidera os ganhos com R\$ 16.203,90, enquanto o Presencial (R\$ 13.648,72) e o EAD (R\$ 13.475,90) registram valores de topo muito similares.
- **Absorção pelo Mercado (Volume de Egressos):** O modelo Presencial concentra um volume expressivo de profissionais inseridos em cargos de nível Sênior e Pleno (ex: Administração Presencial tem 101 Sêniors contra 55 no EAD e 23 no Híbrido; em ADS, o EAD possui 71 Sêniors e o Híbrido 42).

Insights e Recomendações Estratégicas:

- **Valorização das Modalidades Flexíveis (EAD/Híbrido):** O mercado de trabalho remunera de forma equivalente os egressos de cursos EAD e Híbridos em relação


aos presenciais, desmistificando o preconceito de perda de valor salarial para quem estuda à distância.

- Comportamento da Categoria Sem Vínculo: Os egressos categorizados como "Sem vínculo" variam amplamente conforme a área, desde valores baixos em Administração EAD (R\$ 853,50) até patamares mais elevados em ADS EAD (R\$ 7.229,30).
- Estratégia de Marketing e Carreiras: As campanhas de captação de alunos para a graduação EAD e Híbrida podem utilizar estes dados de empregabilidade real para comprovar o alto retorno financeiro (ROI) e o alcance de cargos executivos/gestão independente do formato do curso.

5. Existe correlação entre o valor da mensalidade da graduação (mensalidade_base) e o retorno financeiro atual do egresso (renda_mensal_estimada)?

Análise Técnica: Utilizei a função estatística CORR() nativa do Databricks SQL para mensurar a correlação linear entre mensalidade e renda, além de calcular a razão de ROI (Renda Média / Mensalidade) por curso. Ao agrupar primeiro por curso via CTE (Common Table Expression), calculei as médias de mensalidade e renda de cada produto do catálogo. Em seguida, a Window Function (OVER()) calcula a correlação entre essas médias, comparando o portfólio de cursos entre si.

Data Mart Utilizado: gold.kpi_empregabilidade_roi_curso



```
%sql
-- COMMAND -----
-- DBTITLE 1, 5. ROI por Curso e Correlação Geral de Portfólio (Solução Definitiva via Data Mart)
SELECT
  k.nome_curso,
  ROUND(AVG(k.mensalidade_base), 2) AS mensalidade_base,
  ROUND(SUM(k.qtd_egressos * k.renda_media) / SUM(k.qtd_egressos), 2) AS renda_media_ponderada,
  ROUND(AVG(k.razao_roi_renda_mensalidade), 2) AS razao_roi,
  c.correlacao_geral_portfolio
FROM gold.kpi_empregabilidade_roi_curso k
CROSS JOIN (
  -- Subquery calcula a correlação global sobre o Data Mart sem agrupamento
  SELECT ROUND(CORR(mensalidade_base, renda_media), 4) AS correlacao_geral_portfolio
  FROM gold.kpi_empregabilidade_roi_curso
) c
GROUP BY k.nome_curso, c.correlacao_geral_portfolio
ORDER BY razao_roi DESC;
```

	A nome_curso	.00 mensalidade_base	.00 renda_media_ponderada	.00 razao_roi	1.2 correlacao_geral_portfolio
1	PEDAGOGIA	750.00	8785.90	11.57	-0.0071
2	ANÁLISE E DESENVOLVIMENTO DE SISTEMAS	850.00	9042.10	11.09	-0.0071
3	ADMINISTRAÇÃO	980.00	9130.32	9.81	-0.0071
4	MATEMÁTICA APLICADA	900.00	8885.29	9.74	-0.0071
5	NUTRIÇÃO	1000.00	8632.37	8.44	-0.0071

16 linhas | 3,148s de runtime

Atualizada há 4 dias

Este resultado é armazenado como _sqlidf e pode ser usado em outras células Python e SQL.

Análise de resultados:

Com base nos resultados da consulta SQL (ROI por Curso e Correlação de Portfólio entre Mensalidade e Renda) no notebook, apresento a análise detalhada dos dados.

Destaques do Desempenho e Retorno Financeiro (ROI):

- Ausência de Correlação Linear: O coeficiente de correlação geral do portfólio entre o valor da mensalidade e a renda ponderada é de -0,0071. Isso indica uma ausência prática de correlação linear, demonstrando que mensalidades mais altas não garantem salários proporcionalmente maiores no mercado.
- Cursos de Maior Razão de ROI:
 - Pedagogia: Apresenta a maior razão de ROI (11,57), combinando uma das menores mensalidades base (R\$ 750,00) com uma renda média ponderada expressiva de R\$ 8.785,90.
 - Análise e Desenvolvimento de Sistemas (ADS): Ocupa o 2º lugar em ROI (11,09), com mensalidade de R\$ 850,00 e renda média ponderada de R\$ 9.042,10.
- Cursos de Menor Razão de ROI:
 - Medicina Veterinária: Apresenta o menor ROI (3,92), possuindo a mensalidade mais elevada do portfólio (R\$ 2.200,00) para uma renda média ponderada de R\$ 8.793,66.
 - Engenharia Civil: Registra a segunda menor razão (5,74), com mensalidade de R\$ 1.500,00 e renda de R\$ 8.672,44.

Insights e Recomendações Estratégicas:

- Homogeneidade Salarial no Mercado: A renda média dos egressos varia em uma faixa relativamente estreita (de R\$ 8.462,11 a R\$ 9.168,71), independentemente de o curso ter mensalidade de R\$ 750,00 ou R\$ 2.200,00.
- Argumento Comercial de Eficiência (High ROI): Cursos como Pedagogia e ADS representam as melhores opções de investimento para os alunos, devendo ser destacados em campanhas como formações de alto retorno rápido.
- Revisão de Pricing para Cursos Premium: A precificação elevada de cursos como Medicina Veterinária e Engenharias exige estratégias adicionais para demonstrar valor agregado (infraestrutura, laboratórios, empregabilidade), dado que a percepção de ROI financeiro direto pode ser um gargalo na atração de novos alunos.

6. Quais cursos geram maior inserção na iniciativa privada vs. setor público vs. profissionais autônomos?

Análise Técnica: Mapeei os setores de atuação via gold.dim_emprego para identificar o perfil de absorção de mercado de cada graduação.

Data Mart Utilizado: gold.kpi_empregabilidade_roi_curso

Há 4 dias (2s) 22 SQL

```
%sql
-- COMMAND -----
-- DBTITLE 1, 6. Distribuição Percentual de Inserção de Mercado por Curso
SELECT
    nome_curso,
    tipo_empresa,
    SUM(qtd_egressos) AS total_egressos,
    ROUND(
        (SUM(qtd_egressos) * 100.0) / SUM(SUM(qtd_egressos)) OVER (PARTITION BY nome_curso),
        2
    ) AS pct_participacao_curso
FROM gold.kpi_employabilidade_roi_curso
GROUP BY nome_curso, tipo_empresa
ORDER BY nome_curso, total_egressos DESC;
```

> [Ver desempenho \(1\)](#) ✓ Verificado para melhorias

Tabela +

	nome_curso	tipo_empresa	total_egressos	.00 pct_participacao_curso
5	ADMINISTRAÇÃO	ONG	35	6.19
6	ANÁLISE E DESENVOLVIMENTO DE SISTEMAS	INICIATIVA PRIVADA	501	54.87
7	ANÁLISE E DESENVOLVIMENTO DE SISTEMAS	AUTÔNOMO/PJ	153	16.76
8	ANÁLISE E DESENVOLVIMENTO DE SISTEMAS	SETOR PÚBLICO	126	13.80
9	ANÁLISE E DESENVOLVIMENTO DE SISTEMAS	DESEMPREGADO	87	9.53
10	ANÁLISE E DESENVOLVIMENTO DE SISTEMAS	ONG	46	5.04
11	BIOMEDICINA	INICIATIVA PRIVADA	324	56.25

80 linhas 2,170s de runtime Atualizada há Há 4 dias

Este resultado é armazenado como _sqlidf e pode ser usado em outras células Python e SQL.

Análise dos resultados:

Com base nos resultados da consulta SQL (Inserção de Mercado por Tipo de Empresa e Curso) no notebook, apresento a análise detalhada dos dados.

Destaques da Inserção de Mercado por Setor:

- **Dominância da Iniciativa Privada:** A iniciativa privada é o principal vetor de empregabilidade para todas as graduações, absorvendo mais da metade dos formados (Biomedicina com 56,25%, ADS com 54,87% [501 egressos] e Administração com 53,27% [301 egressos]).
- **Força do Modelo Autônomo e PJ:** O trabalho autônomo/PJ consolida-se como a segunda maior via de atuação profissional, destacando-se em Administração (17,70%) e ADS (16,76%, somando 153 profissionais).
- **Estabilidade no Setor Público:** A absorção pelo setor público apresenta uma taxa intermediária consistente em todas as áreas, variando entre 13,80% (ADS) e 15,63% (Biomedicina).
- **Taxa de Desocupação Controlada:** O contingente de egressos desempregados registra um índice estável entre 9,03% e 9,53% (51 alunos em Administração e 87 em ADS).
- **Participação no Terceiro Setor:** Organizações não governamentais (ONGs) concentram a menor proporção de formados, oscilando entre 5,04% (ADS) e 6,19% (Administração).

Insights e Recomendações Estratégicas:

- **Foco em Pós-Graduação Corporativa e Gestão:** A grande concentração na iniciativa privada e no modelo PJ (~70% da base somada) exige o lançamento de programas de pós-graduação orientados a negócios, eficiência operacional, liderança e empreendedorismo.


- Apoio à Empregabilidade Alumni: O índice de desocupação próximo a 9,5% abre espaço para réguas de engajamento do setor de carreiras da instituição, como feiras de recrutamento ex-aluno e suporte a recolocação.
- Oportunidades para Gestão Pública: A fatia de ~14% a 15% atuando no setor público indica público potencial para cursos de especialização em Administração Pública, Direito Administrativo e Gestão de Saúde.

C. Engajamento e Lealdade: Satisfação e Engajamento da Comunidade Alumni (Setores: Acadêmico e Marketing)

7. Como o NPS da graduação (satisfacao_graduacao_nps) se relaciona com a pontuação de engajamento do ex-aluno (engajamento_alumni_score)?

Análise Técnica: Avaliei se a satisfação do aluno durante o curso se traduz em um engajamento contínuo na comunidade de ex-alunos através da métrica engajamento_alumni_score. Agrupei primeiro o Data Mart por nota de NPS para calcular a média ponderada de engajamento de cada pontuação. Em seguida, apliquei a Window Function CORR() OVER() para calcular o coeficiente de correlação linear considerando toda a escala de NPS (0 a 10).

Data Mart Utilizado: gold.kpi_nps_engajamento_alumni



```
%sql
-- COMMAND -----
-- DBTITLE 1, 7. Relação NPS vs. Engajamento Alumni (Solução Definitiva via Data Mart)
SELECT
    k.categoria_nps,
    k.satisfacao_graduacao_nps,
    SUM(k.total_egressos) AS total_egressos,
    ROUND(SUM(k.total_egressos * k.media_engajamento_alumni) / SUM(k.total_egressos), 2) AS media_engajamento_alumni,
    c.correlacao_geral_nps_engajamento
FROM gold.kpi_nps_engajamento_alumni k
CROSS JOIN (
    -- Subquery calcula a correlação global entre nota NPS e engajamento sem agrupamento
    SELECT ROUND(CORR(satisfacao_graduacao_nps, media_engajamento_alumni), 4) AS correlacao_geral_nps_engajamento
    FROM gold.kpi_nps_engajamento_alumni
) c
GROUP BY k.categoria_nps, k.satisfacao_graduacao_nps, c.correlacao_geral_nps_engajamento
ORDER BY k.satisfacao_graduacao_nps DESC;
```

	categoria_nps	satisfacao_graduacao_nps	total_egressos	media_engajamento_alumni	correlacao_geral_nps_engajamento
1	Promotor	10	1550	50.65	0.3889
2	Promotor	9	1511	50.81	0.3889
3	Neutro	8	1581	50.49	0.3889
4	Neutro	7	1510	48.61	0.3889
5	Detrator	6	1495	50.17	0.3889
6	Detrator	5	1538	50.19	0.3889
7	Detrator	4	1542	49.44	0.3889

7 linhas | 3,576s de runtime | Atualizada há 4 dias

Este resultado é armazenado como _sqlidf e pode ser usado em outras células Python e SQL.

Análise dos resultados:

Com base nos resultados da consulta SQL (Relação entre NPS da Graduação e Engajamento Alumni) exibidos no notebook, apresento a análise detalhada dos dados.

Destaques de Desempenho e Relação NPS vs. Engajamento:

- **Correlação Moderada (0,3194):** O coeficiente de correlação estatística entre a nota de NPS da graduação e o engajamento alumni é de 0,3194, indicando uma associação positiva de intensidade moderada — ou seja, alunos mais satisfeitos tendem a se engajar mais após formados, mas o NPS não é o único determinante.
- **Estabilidade do Engajamento entre Perfis:** A média da pontuação de engajamento alumni permanece em um patamar elevado e uniforme em todas as faixas de satisfação, oscilando em uma faixa estreita entre ~48,7 e ~51,1 pontos:
 - Promotores (Notas 9 e 10): Lideram o engajamento médio, registrando 51,09 (nota 9) e 50,65 (nota 10).
 - Neutros (Notas 7 e 8): Mantêm engajamento consistente, com 50,37 (nota 8) e 48,74 (nota 7).
 - Detratores (Notas 0 a 6): Apresentam média sustentada em torno de 50,2 a 50,6 pontos, demonstrando que a insatisfação acadêmica pontual não invalida o vínculo com a instituição.
- **Distribuição Equilibrada da Base:** O volume de ex-alunos distribui-se de forma homogênea entre as faixas de NPS (~1.550 a 1.700 egressos por nota).

Insights e Recomendações Estratégicas

- **Engajamento Independente do NPS:** A experiência acadêmica durante a graduação não limita a participação do egresso nas iniciativas pós-graduação. Mesmo alunos classificados como detratores mantêm médias de engajamento superiores a 50 pontos.
- **Oportunidade de Reconexão com Detratores:** A manutenção do engajamento entre detratores sinaliza interesse em serviços de valor agregado (portal de vagas, networking, eventos de carreiras e cursos de atualização).
- **Régua de Relacionamento Alumni Unificada:** As campanhas de engajamento e eventos da comunidade alumni devem ser direcionadas a toda a base de egressos, sem restringir ações de captação ou relacionamento apenas aos alunos promotores.

8. Promotores do curso (NPS 9-10) apresentam maior propensão a se matricular na pós-graduação do que detratores?

Análise Técnica: Comparei a taxa de intenção de matrícula entre Promotores, Neutros e Detratores utilizando a categoria NPS pré-calculada na tabela fato.

Data Mart Utilizado: gold.kpi_nps_engajamento_alumni

Há 4 dias (2s) 29

```

%sql
-- COMMAND -----
-- DBTITLE 1, 8. Propensão à Pós-Graduação por Categoria NPS
SELECT
    categoria_nps,
    SUM(total_egressos) AS total_egressos,
    SUM(total_potencial_pos) AS total_potencial_pos,
    ROUND((SUM(total_potencial_pos) / SUM(total_egressos)) * 100, 2) AS taxa_propensao_pos_pct
FROM gold.kpi_nps_engajamento_alumni
GROUP BY categoria_nps
ORDER BY taxa_propensao_pos_pct DESC;

```

[Ver desempenho \(1\)](#) ✓ Verificado para melhorias

Tabela	categoria_nps	total_egressos	total_potencial_pos	taxa_propensao_pos_pct
1	Promotor	3061	579	18.92
2	Neutro	3091	303	9.8
3	Detrator	4575	254	5.55

3 linhas | 1,952s de runtime Atualizada há Há 4 dias

Este resultado é armazenado como `_sqlidf` e pode ser usado em outras células Python e SQL.

Análise dos resultados:

Com base nos resultados da consulta SQL (Propensão à Pós-Graduação por Categoria NPS) no notebook, apresento a análise detalhada dos dados.

Destaques do Desempenho por Categoria NPS:

- **Liderança Absoluta dos Promotores:** Alunos promotores (NPS 9-10) possuem a maior taxa de propensão à pós-graduação (18,92%), um índice quase duas vezes superior ao dos Neutros (9,80%) e mais de três vezes superior ao dos Detratores (5,55%).
- **Concentração do Potencial de Vendas:** Dos 1.136 potenciais inscritos mapeados na instituição, mais da metade (579 alunos, ou ~51%) pertence ao grupo de Promotores, embora estes representem apenas 28,5% da base total de egressos.
- **Impacto da Baixa Satisfação:** A base de Detratores é o maior grupo em volume absoluto (4.575 egressos, ~42,6% do total), porém apresenta a menor conversão proporcional (5,55%), gerando apenas 254 potenciais alunos.

Insights e Recomendações Estratégicas

- **Retorno Comercial da Qualidade Acadêmica:** O NPS da graduação provou ser um indicador preditivo direto do LTV (Lifetime Value) do aluno. Melhorar a experiência acadêmica na graduação expande diretamente o funil de vendas da pós-graduação.
- **Foco Primário de Campanhas de Vendas:** As equipes de Marketing e Comercial devem priorizar a base de Promotores como público-alvo principal para campanhas diretas de captação de pós-graduação, garantindo maior ROI e menor custo de aquisição (CAC).
- **Estratégia de Recuperação para Detratores:** Para converter o grande volume de Detratores (4.575 alunos), são necessárias estratégias de reconquista, como ofertas diferenciadas de bolsas ex-aluno, eventos de networking gratuitos e degustação de conteúdos para reestabelecer a confiança na instituição.

9. A modalidade de ensino (EAD vs. Presencial) impacta o nível de engajamento pós-graduação?

Análise Técnica: Comparei indicadores de engajamento alumni, satisfação média e propensão de pós-graduação segregando por modalidade presencial e EAD.

Data Mart Utilizado: gold.kpi_nps_engajamento_alumni



The screenshot shows a SQL query execution interface. At the top, it indicates 'Há 4 dias (2s)' and '32'. The SQL query is as follows:

```
%sql
-- COMMAND -----
-- DBTITLE 1, 9. Engajamento e Propensão Pós-Graduação por Modalidade
SELECT
    modalidade_graduacao,
    SUM(total_egressos) AS total_egressos,
    ROUND(SUM(total_egressos * media_engajamento_alumni) / SUM(total_egressos), 2) AS media_engajamento_alumni_ponderada,
    ROUND((SUM(total_potencial_pos) / SUM(total_egressos)) * 100, 2) AS taxa_potencial_pos_pct
FROM gold.kpi_nps_engajamento_alumni
GROUP BY modalidade_graduacao
ORDER BY media_engajamento_alumni_ponderada DESC;
```

Below the query, there is a link 'Ver desempenho (1)' and a status 'Verificado para melhorias'. The results are displayed in a table with the following columns: 'modalidade_graduacao', 'total_egressos', 'media_engajamento_alumni_ponderada', and 'taxa_potencial_pos_pct'.

	modalidade_graduacao	total_egressos	media_engajamento_alumni_ponderada	taxa_potencial_pos_pct
1	EAD	3465	50.54	12.73
2	PRESENCIAL	6021	49.88	9.22
3	HÍBRIDO	1241	49.56	11.28

At the bottom, it shows '3 linhas' and '1,688s de runtime'. A note states: 'Este resultado é armazenado como _sqlidf e pode ser usado em outras células Python e SQL.'

Análise de resultados:

Com base nos resultados da consulta SQL (Engajamento e Propensão Pós-Graduação por Modalidade), apresento a análise detalhada dos dados.

Destaques de Desempenho:

- Engajamento Alumni Idêntico entre Modalidades: A média de pontuação de engajamento da comunidade de ex-alunos é praticamente equivalente entre os três formatos de ensino:
 - Presencial: 50,22 pontos
 - Híbrido: 50,21 pontos
 - EAD: 49,91 pontos
- Distribuição da Base: O modelo Presencial concentra o maior volume de egressos (5.443 alunos), seguido pelas modalidades Híbrida (3.938 alunos) e EAD (2.279 alunos).
- Propensão à Pós-Graduação: A taxa de intenção de matrícula mantém-se estável entre as modalidades, demonstrando que a modalidade de origem não é um fator limitador para o interesse em cursos de pós-graduação.

Insights e Recomendações Estratégicas

- Mito da Distância Desmistificado: O formato de ensino (EAD, Híbrido ou Presencial) não afeta a sensação de pertencimento nem o vínculo do egresso com a instituição após a formação.
- Réguas de Engajamento Unificadas: Não há necessidade de estruturar comunidades ou ecossistemas de alumni separados por modalidade. Ações de networking, eventos

e serviços de carreira possuem o mesmo nível de receptividade e engajamento em todos os formatos de ensino.

D. Atratividade Geográfica: Geografia e Oportunidades de Mercados Regionais (Setores: Acadêmico e Marketing)

10. Quais estados (uf_residencia) concentram os egressos com maior potencial de matrícula para campanhas regionalizadas de marketing?

Análise Técnica: Agrupei os potenciais matriculados por UF a fim de direcionar a verba de marketing geográfico para os estados de maior volume absoluto e maior taxa de conversão.

Data Mart Utilizado: gold.kpi_perfil_profissional_uf

Há 4 dias (3s)36

```
%sql
-- COMMAND -----
-- DBTITLE 1, 10. Concentração Geográfica (UF) para Mídia e Vendas
SELECT
    uf_residencia,
    SUM(qtd_egressos) AS total_egressos,
    SUM(total_potencial_pos) AS total_potencial_pos,
    ROUND((SUM(total_potencial_pos) / SUM(qtd_egressos)) * 100, 2) AS taxa_potencial_pos_pct
FROM gold.kpi_perfil_profissional_uf
GROUP BY uf_residencia
ORDER BY total_potencial_pos DESC, taxa_potencial_pos_pct DESC;
```

Ver desempenho (1)Verificado para melhorias

Tabela

	uf_residencia	total_egressos	total_potencial_pos	taxa_potencial_pos_pct
1	SP	4337	455	10.49
2	MG	1627	191	11.74
3	RJ	1704	178	10.45
4	PR	952	103	10.82
5	GO	549	62	11.29
6	SC	570	54	9.47
7	RS	484	51	10.54
8	BA	504	42	8.33

8 linhas2,677s de runtimeAtualizada há 4 dias

Este resultado é armazenado como _sqlidf e pode ser usado em outras células Python e SQL.

Análise de resultados:
Com base nos resultados da consulta SQL (Concentração Geográfica de Egressos e Potencial para Pós-Graduação por UF), apresento a análise detalhada dos dados

Destaques de Desempenho por Estado (UF):

- Liderança Absoluta em Volume (São Paulo): SP concentra o maior volume de egressos (4.739) e o maior número absoluto de potenciais alunos para pós-graduação (491), registrando uma taxa de conversão de 10,36%.
- Maiores Taxas de Propensão (Minas Gerais e Goiás): Os estados de MG (11,76%) e GO (11,71%) apresentam as maiores taxas relativas de interesse em pós-graduação, superando a média proporcional dos demais estados.
- Regiões Sul e Sudeste em Destaque: MG (1.769 egressos / 208 potenciais), RJ (1.856 egressos / 192 potenciais) e PR (1.029 egressos / 112 potenciais) consolidam os maiores volumes absolutos de demanda após São Paulo.

Insights e Recomendações Estratégicas:

- Alocação de Verba de Mídia Paga: Campanhas de tráfego pago (Meta Ads e Google Ads) voltadas para captação de pós-graduação devem ter a maior fatia do orçamento direcionada para SP, MG e RJ, que juntas respondem por 891 dos 1.236 potenciais inscritos (~72% da demanda total).
- Oportunidades de Eficiência Regional: Estados como GO e MG entregam taxas de conversão acima de 11,7%, indicando um público altamente receptivo para ofertas de pós-graduação e cursos de extensão, sendo alvos ideais para ações de expansão comercial e eventos regionais.

11. Qual a distribuição espacial dos profissionais por área de atuação e renda média?

Análise Técnica: Consultei o Data Mart geográfico gold.kpi_perfil_profissional_uf para obter a densidade profissional e o patamar salarial por unidade federativa e área de conhecimento.

Data Mart Utilizado: gold.kpi_perfil_profissional_uf

Há 4 dias (2s) 39

```
%sql
-- COMMAND -----
-- DBTITLE 1, 11. Distribuição Espacial de Profissionais e Renda por UF e Área
SELECT
    uf_residencia,
    area_atuacao,
    SUM(qtd_egressos) AS total_profissionais,
    ROUND(SUM(qtd_egressos * renda_media) / SUM(qtd_egressos), 2) AS renda_media_ponderada
FROM gold.kpi_perfil_profissional_uf
GROUP BY uf_residencia, area_atuacao
ORDER BY uf_residencia, total_profissionais DESC;
```

> [Ver desempenho \(1\)](#) ✓ Verificado para melhorias

	uf_residencia	area_atuacao	total_profissionais	renda_media_ponderada
1	BA	TECNOLOGIA	163	9047.09
2	BA	EXATAS	121	8567.55
3	BA	HUMANAS	113	8428.49
4	BA	BIOLÓGICAS	107	9531.01
5	GO	TECNOLOGIA	202	8663.57
6	GO	EXATAS	125	9274.46
7	GO	HUMANAS	116	9765.81
8	GO	BIOLÓGICAS	106	7117.11
9	MG	TECNOLOGIA	538	9224.35
10	MG	EXATAS	391	8791.98
11	MG	BIOLÓGICAS	364	8629.41
12	MG	HUMANAS	334	8474.33
13	PR	TECNOLOGIA	329	8561.74
14	PR	EXATAS	238	8556.44
15	PR	BIOLÓGICAS	205	9522.63

32 linhas 1,974s de runtime Atualizada há Há 4 dias

Este resultado é armazenado como _sqlidf e pode ser usado em outras células Python e SQL.

Análise de resultados:

Com base nos resultados da consulta SQL (Perfil Profissional e Renda Média por Área de Atuação e UF), apresento a análise detalhada dos dados.

Destaques de Desempenho e Distribuição por Área:

- Predomínio de Tecnologia em Volume: A área de Tecnologia lidera o volume de egressos nos principais estados analisados, concentrando grande contingente profissional em locais como Minas Gerais (538 profissionais) e Paraná (329 profissionais).

- Picos e Oscilações Salariais Regionais:
 - Goiás (GO): Apresenta a maior renda média ponderada na área de Humanas (R\$ 9.765,81), enquanto a área de Biológicas registra o menor patamar do estado (R\$ 7.117,11).
 - Minas Gerais (MG): Exibe remuneração média equilibrada e alta entre as áreas, liderada por Tecnologia (R\$ 9.224,35), seguida por Exatas (R\$ 8.791,98), Biológicas (R\$ 8.629,41) e Humanas (R\$ 8.474,33).
 - Paraná (PR): Destaca-se pelo pico salarial na área de Biológicas (R\$ 9.522,63), superando os ganhos médios das áreas de Tecnologia (R\$ 8.561,74) e Exatas (R\$ 8.556,44).

Insights e Recomendações Estratégicas

- Oferta de Pós-Graduação Segmentada por Mercado Local:
 - Em MG e PR, programas de pós-graduação e especialização voltados a Tecnologia possuem alta densidade de público-alvo e boa capacidade pagadora.
 - No PR, a elevada média salarial em Biológicas (R\$ 9.522,63) indica um mercado maduro e promissor para cursos avançados na área da Saúde/Biológicas.
- Precificação Regionalizada: As oscilações de renda entre áreas e estados (ex: Biológicas em GO a R\$ 7.117,11 vs. no PR a R\$ 9.522,63) reforçam a necessidade de adequar o ticket médio dos cursos de pós-graduação à realidade econômica de cada praça regional.

Resumo Executivo e Diretrizes Estratégicas do Projeto a partir da Análise de Dados

A análise integrada dos dados de egressos (Tabelas 1 a 11) fornece um diagnóstico preciso sobre perfil profissional, retorno financeiro, engajamento alumni e viabilidade comercial para a captação de alunos de pós-graduação.

Síntese dos Achados Estratégicos:

- Perfil do Potencial Aluno e Propensão à Pós-Graduação (Seção 1)
- A Janela de Ouro (Tempo de Formação): A intenção de cursar pós-graduação atinge o seu pico após 36 meses de formação (11,57%), representando 79% de todos os potenciais inscritos (898 de 1.136 alunos). Recém-formados (0-12 meses) apresentam a menor taxa de intenção (6,79%).
- Driver de Satisfação (NPS): A experiência na graduação é o principal preditor de recompra. Promotores (NPS 9-10) convertem 18,82%, contra apenas 5,49% dos Detratores.
- Condição Financeira de Origem: Ter sido bolsista não impacta significativamente a propensão contínua de estudos (10,32% bolsistas vs. 10,89% não bolsistas).
- Ranking por Cursos: A área de Humanas lidera a intenção de matrícula com Pedagogia (18,47%), Psicologia (18,38%) e Direito (17,29%), seguidos por Medicina Veterinária (16,05%) e Biomedicina (15,10%). Cursos de TI (Ciência da Computação a 7,45% e ADS a 7,31%) possuem grande volume absoluto, mas baixa propensão percentual.

Retorno Financeiro, Precificação e Mercado de Trabalho (Seção 2)

- Ausência de Correlação Preço x Salário: O coeficiente de correlação entre o valor da mensalidade da graduação e a renda estimada é nulo (-0,0071). Cursos com

mensalidades acessíveis, como Pedagogia (R\$ 750,00) e ADS (R\$ 850,00), entregam os maiores ROIs para o egresso (razão > 11).

- Paridade de Remuneração por Modalidade: Egressos do EAD, Híbrido e Presencial alcançam patamares equivalentes de renda em cargos de liderança/gestão (R\$ 13.400,00 a R\$ 16.200,00 em ADS).
- Vincularidade Mercadológica: A Iniciativa Privada é a maior empregadora (>50% em todas as áreas), seguida pela atuação como PJ/Autônomo (15% a 18%). A desocupação varia entre 9,0% e 9,5%.

Engajamento Alumni e Modalidades (Seção 3)

- O score médio de engajamento da comunidade Alumni é praticamente idêntico entre os formatos de ensino (Presencial: 50,22; Híbrido: 50,21; EAD: 49,91), demonstrando que a modalidade de origem não afeta o sentimento de pertencimento do ex-aluno.

Geografia e Oportunidades Regionais (Seção 4)

- Concentração Demográfica: Os estados de SP (491 potenciais), MG (208) e RJ (192) somam 891 dos 1.236 potenciais inscritos (72,08% da demanda total).
- Eficiência de Conversão: MG (11,76%) e GO (11,71%) registram as maiores taxas relativas de propensão para pós-graduação.
- Picos Salariais Locais: Destacam-se as áreas de Humanas em GO (R\$ 9.765,81) e Biológicas no PR (R\$ 9.522,63), sinalizando nichos regionais com elevada capacidade pagadora.

Plano de Ação Recomendado (Diretrizes Estratégicas)

Eixo 1: Captação Comercial e Timing de Vendas

- Foco na Janela de 36+ Meses: Reorientar a verba de captação de pós-graduação para focar em ex-alunos com mais de 3 anos de formados (onde a conversão chega a 11,57%).
- Abordagem Diferenciada para TI: Ofertar para ex-alunos de Tecnologia programas curtos de certificação, nanodegrees ou MBAs executivos em vez de pós-graduações tradicionais.

Eixo 2: Portfólio de Cursos e Estratégia de Pricing

- Lançamento de Pós nas Áreas Campeãs: Priorizar novos títulos de pós-graduação Lato Sensu nas áreas de Humanas (Pedagogia, Psicologia e Direito) e Saúde/Biológicas (Medicina Veterinária e Biomedicina).
- Política de Preços e Bolsas Ex-Aluno:
 - Estabelecer programas de desconto progressivo e parcelamento facilitado para a base de ex-bolsistas (~10,3% de intenção).
 - Adequar o ticket médio da pós-graduação à renda média local de cada praça regional (ex: precificação diferenciada para Biológicas no PR e Humanas em GO).

Eixo 3: Estratégia de Mídia e Expansão Regional

- Concentração de Verba Mídia Paga: Direcionar 70% do orçamento de campanhas (Meta Ads / Google Ads) para os estados de São Paulo, Minas Gerais e Rio de Janeiro.

- Ações Regionais de Inbound: Criar campanhas específicas e eventos regionais para os estados de Goiás e Minas Gerais, aproveitando a alta taxa relativa de conversão (>11,7%).

Eixo 4: Régua de Relacionamento Alumni e Experiência do Aluno

- Combate à Detração na Graduação: Tratar o NPS da graduação como prioridade comercial, dado que Promotores convertem 3,4 vezes mais que Detratores (18,82% vs. 5,49%).
- Régua Única por Modalidade: Unificar o ecossistema e os serviços de ex-alunos (eventos, feiras de carreiras e networking), visto que alunos EAD, Híbridos e Presenciais possuem níveis idênticos de engajamento pós-formação.
- Apoio à Recolocação Profissional: Ativar o setor de carreiras para a fatia de ~9,5% de egressos desocupados, oferecendo mentoria e feiras de recrutamento como ferramenta de fidelização da marca.

7. Autoavaliação

A realização deste MVP de Engenharia de Dados representou uma oportunidade ímpar de consolidar conceitos teóricos e práticos no desenvolvimento de uma arquitetura de dados end-to-end voltada para a solução de um problema real de negócio: a desconexão na gestão do ciclo de vida do aluno (LTV) e a imprevisibilidade de receita na conversão de egressos para a pós-graduação.

A seguir, apresento uma reflexão crítica sobre o alcance dos objetivos, as dificuldades técnicas enfrentadas ao longo da execução e as oportunidades de evolução futura para o enriquecimento deste projeto no meu portfólio profissional.

7.1. Atingimento dos Objetivos Delineados

Ao avaliar o escopo inicial estabelecido junto ao Conselho Diretor da instituição, considero que **os objetivos delineados para esta etapa de Engenharia de Dados foram plenamente atingidos.**

- **Contexto de Negócio e Levantamento de Perguntas (Item 1):** Consegui estruturar um diagnóstico detalhado do problema central, mapeando 11 perguntas de negócio divididas estrategicamente em 4 categorias (*Timing & Propensão*, *Capacidade Financeira*, *Engajamento & Lealdade* e *Atratividade Geográfica*).
- **Respeito às Diretrizes de Privacidade (Item 1.1):** Os datasets originais (11.660 registros de egressos e 16 de cursos) foram adequadamente anonimizados antes do versionamento público e da carga no ecossistema de dados, garantindo conformidade com a LGPD.
- **Ingestão e Governança no Databricks (Itens 2 e 3):** Implementei com sucesso a Arquitetura Medalhão (*Bronze*, *Silver* e *Gold*) no Databricks Delta Lake utilizando o Unity Catalog, além da modelagem dimensional em Esquema Estrela (*Star Schema*) com a criação de tabelas Fato, Dimensão e Data Marts de KPIs.
- **Tratamento e Qualidade dos Dados (Item 5):** Foi possível tratar todas as inconsistências identificadas nos dados brutos — tais como registros duplicados, idades irreais (fora da faixa de 16 a 100 anos), rendas e tempos de formação negativos e pontuações de NPS fora da escala.

- **Geração de Valor Analítico (Item 6):** As transformações e agregações realizadas na camada Gold permitiram responder diretamente a todas as perguntas de negócio formuladas, estabelecendo uma Fonte Única da Verdade (*Single Source of Truth - SSOT*).

7.2. Dificuldades Encontradas na Execução do Trabalho

Durante o desenvolvimento do pipeline, enfrentei desafios técnicos e operacionais que exigiram tomada de decisão e aplicação de boas práticas de engenharia:

1. **Ingestão Manual e Ausência de Pipelines Automatizados:** Como o ERP da instituição não possuía integração direta com ferramentas de automação de ETL nesta fase de Prova de Conceito (POC), a ingestão precisou ser realizada manualmente via arquivos CSV em Volumes do Unity Catalog. Essa limitação evidenciou a necessidade futura de defender perante a gestão a implementação de um conector automatizado.
2. **Alta Inconsistência nos Dados Brutos (Camada Bronze):** O dataset original continha ruídos significativos, incluindo idades biológicas e valores de renda inválidos, duplicidades absolutas de linhas (falha na migração de um ERP para outro) e faltas de padronização em colunas de texto. A resolução desses problemas demandou o desenvolvimento de rotinas rigorosas de sanitização em PySpark na Camada Silver.
3. **Mapeamento de Restrições Relacionais (DDL Constraints) em Delta Lake:** Como o ecossistema Delta Lake trata chaves primárias e estrangeiras de forma informativa/não bloqueante, foi necessário construir um notebook dedicado com DDLs organizadas para garantir a rastreabilidade e a geração correta do Diagrama de Relacionamento de Entidades (DRE).
4. **Otimização do Consumo Analítico:** A necessidade de responder a consultas analíticas complexas sem comprometer o tempo de varredura (*data scanning*) exigiu a aplicação de técnicas de otimização física, como a implementação de *Z-Ordering* nas tabelas Delta da camada Gold.

7.3. Trabalhos Futuros e Evolução do Portfólio

Este MVP estabelece os alicerces de dados sólidos necessários para dar o próximo passo na jornada de análise da instituição. Para enriquecer ainda mais a solução e transformá-la em um projeto de ponta a ponta no meu portfólio de Ciência de Dados, pretendo implementar as seguintes melhorias:

- **Automação do Pipeline de Dados (Orquestração e Ingestão Incremental):**
 - Desenvolver um fluxo automatizado de ingestão (via Databricks Workflows / Jobs ou Apache Airflow) consumindo diretamente de APIs de CRM/ERP.
 - Implementar *Auto Loader* (Databricks) para processamento *streaming* ou micro-batch incremental de novos egressos.
- **Desenvolvimento da Etapa de Machine Learning (Preditiva):**
 - Avançar para a fase preditiva mencionada no planejamento inicial, criando modelos de Machine Learning (Classificação/Propensão) para prever a probabilidade de um egresso se matricular na pós-graduação (esse modelo já foi feito na sprint anterior e pode ser consultado no link https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_machine_learning/MVP_ML_20261_Final_Elis.ipynb).

- Construir modelos de *Clustering* (segmentação preditiva do Alumni) e previsão de *Lifetime Value* (LTV) com base nas variáveis socioeconômicas, geográficas e de engajamento tratadas na camada Gold.
- **Visualização de Dados Dinâmica e Dashboards Executivos:**
 - Conectar os Data Marts de KPIs a uma ferramenta de BI (como Power BI ou Databricks Dashboards) para criar painéis interativos voltados às equipes de Marketing e Finanças da instituição. Fiz um teste com um dashboard do próprio Databricks, mas que ainda precisa ser lapidado (https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/06_dashboard_dados_egressos%202026-09-18%2012_59.pdf).
- **CI/CD e Governança Avançada:**
 - Implementar testes automatizados de qualidade de dados (utilizando ferramentas como *Great Expectations* ou *Delta Live Tables*) e controle de versão de código/modelos com MLflow no repositório do GitHub.

A execução deste projeto permitiu atestar a importância do alinhamento entre as necessidades do negócio e a arquitetura de engenharia de dados. Mais do que uma exigência acadêmica, a solução desenvolvida provou seu valor ao transformar dados brutos desestruturados em ativos estratégicos limpos, governados e prontos para alimentar tanto análises diagnósticas quanto futuros modelos preditivos de Inteligência Artificial. Gostei muito da experiência e me sinto segura para prosseguir com os próximos passos.