

RELATÓRIO COM O DETALHAMENTO DAS ETAPAS DESENVOLVIDAS NO MVP

ALUNA: Elisandra André Maranhe
SPRINT: Engenharia de Dados
RA: 4052026000054

1. Contexto de Negócios e Perguntas (Etapa 2 e 4.1)

Trabalho em uma instituição educacional de ensino superior que tem vários cursos e o nosso foco de análise de mercado nesse momento são os cursos de pós-graduação, haja vista estarmos fazendo uma reestrutura nas ofertas.

Atualmente, a nossa instituição investe no desenvolvimento de novos cursos de pós-graduação baseando-se, muitas vezes, em intuição ou em tendências genéricas de mercado. No entanto, entendo que corremos o risco de faturar menos por oferecer produtos acadêmicos para um público que exige soluções altamente práticas e voltadas para o mercado corporativo.

Nesse sentido, o problema central que perpassa todas as perguntas de negócio que apresentarei a seguir é a **desconexão entre a gestão do ciclo de vida do aluno (LTV – Lifetime Value) e a previsibilidade de receita na conversão de egressos para a Pós-Graduação**.

Diante **deste problema**, entre as medidas iniciais cabíveis, reuni-me com o Conselho Diretor da instituição para levantarmos análises que possam nos ajudar com respostas ao cenário que vivenciamos hoje. Trabalhamos com Sistemas ERP, CRM e Plataforma de Egressos gerando dados importantes para essa análise. Porém, era preciso entendermos quais as principais perguntas de negócio que poderiam ser respondidas (ou não) a partir destes dados, e que pudessem nos guiar em ações práticas para sanar o nosso problema inicial.

A partir desta reunião, consegui levantar as perguntas de negócio e dividi-las em quatro categorias. As quatro não abordam problemas isolados; pelo contrário, elas tentam resolver a ineficiência na alocação de esforços de marketing e vendas (Up-sell) por falta de um modelo de propensão e segmentação preditiva do Alumni. Esse é o objetivo final de todo o processo de análise, ou seja, iniciar a análise com respostas diagnóstica e chegar a um modelo preditivo futuramente (esta parte deixarei para um segundo momento, pois envolverá a criação de um modelo de Machine Learning).




Figura 1 – Categorias levantadas para análise de dados.

Portanto, descrevo a seguir as perguntas de negócio que tem como objetivo serem respondidas a partir da análise dos dados trabalhados neste MVP.

A. Timing e Propensão (Potencial de conversão e captação de pós-graduação)

- Setores envolvidos: Marketing e Financeiro
- Perguntas de negócio:
 - Qual é a taxa de conversão (*potencial_matricula_pos*) por curso (*nome_curso*) e por área do conhecimento?
 - Qual o tempo ideal após a graduação (*meses_desde_formacao*) em que os egressos demonstram maior intenção de matrícula?
 - Ex-bolsistas de graduação (*bolsista_graduacao*) possuem maior probabilidade de continuar os estudos em comparação aos não bolsistas?

B. Capacidade Financeira (Empregabilidade e perfil socioeconômico)

- Setores envolvidos: Marketing e Financeiro
- Perguntas de negócio:
 - Qual é a renda média e a distribuição de cargos (*nivel_cargo*) por curso e por modalidade (*modalidade_graduacao*)?
 - Existe correlação entre o valor da mensalidade da graduação (*mensalidade_base*) e o retorno financeiro atual do egresso (*renda_mensal_estimada*)?
 - Quais cursos geram maior inserção na iniciativa privada vs. setor público vs. profissionais autônomos?

C. Engajamento e Lealdade (Satisfação e Engajamento da Comunidade Alumni)

- Setores envolvidos: Acadêmico e Marketing
- Perguntas de negócio:
 - Como o NPS da graduação (*satisfacao_graduacao_nps*) se relaciona com a pontuação de engajamento do ex-aluno (*engajamento_alumni_score*)?
 - Promotores do curso (NPS 9-10) apresentam maior propensão a se matricular na pós-graduação do que detratores?
 - A modalidade de ensino (EAD vs. Presencial) impacta o nível de engajamento pós-formação?

D. Atratividade Geográfica (Geografia e Oportunidades de Mercados Regionais)

- Setores envolvidos: Acadêmico e Marketing
- Perguntas de negócio:
 - Quais estados (*uf_residencia*) concentram os egressos com maior potencial de matrícula para campanhas regionalizadas de marketing?

- Qual a distribuição espacial dos profissionais por área de atuação e renda média?


1.1. Sobre os datasets utilizados: tipo, estrutura e licença

Para poder responder a todas estas perguntas, busquei trabalhar com dados de uma de nossas plataformas (ERP). Atualmente, ela não faz integração direta com nenhuma ferramenta que automatize o ETL. Mas a intenção futura com este projeto é mostrar o ganho que podemos ter neste sentido para o Conselho Diretor da instituição. Sendo assim, os datasets foram extraídos em formato “csv” (forma bruta), baixados para meu computador e feito a ingestão manual futura no Databricks (mais detalhes serão apresentados adiante).

Trabalhei com dois *datasets* em que o primeiro apresentava 15 atributos com um total de 11.660 linhas, e o segundo 5 atributos e 16 linhas, como mostram as Figuras 2 e 3. Ambos podem ser acessados diretamente no GitHub pelo link:

https://github.com/elis2637/posgrad_pucrio/tree/main/sprint_engenharia_dados/dataset.

Para que pudessem ser utilizados respeitando a LGPD, os ID reais dos egressos, bem como seus respectivos nomes foram eliminados. Com isso, foi inserida uma coluna com IDs sequenciados de 1 a 11.660, mantendo o anonimato dos egressos. Estes ajustes foram feitos antes da ingestão no Databricks, para que fosse possível disponibilizá-los, também, no GitHub, haja vista ser um repositório público.



	A	B	C	D	E
	id_curso	nome_curso	area_conhecimento	duracao_semestres	mensalidade_base
1	101	Ciência da Computação	Tecnologia	8	1200
2	102	Análise e Desenvolvimento de Sistemas	Tecnologia	5	850
3	103	Sistemas de Informação	Tecnologia	8	1050
4	104	Engenharia de Software	Tecnologia	9	1350
5	201	Engenharia Civil	Exatas	10	1500
6	202	Engenharia de Produção	Exatas	10	1400
7	203	Matemática Aplicada	Exatas	8	900
8	204	Estatística e Ciência de Dados	Exatas	8	1150
9	301	Administração	Humanas	8	980
10	302	Direito	Humanas	10	1600
11	303	Psicologia	Humanas	10	1300
12	304	Pedagogia	Humanas	8	750
13	401	Medicina Veterinária	Biológicas	10	2200
14	402	Enfermagem	Biológicas	9	1250
15	403	Biomedicina	Biológicas	8	1100
16	404	Nutrição	Biológicas	8	1000

Figura 2 – Dataset cursos (csv) gerado de Plataforma ERP da instituição.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	id_egresso	id_curso	id_universidade	nome_aluno	nome_curso	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao	nome_instituicao
2	1	103	2020-02-02	MD	109	21	Sem vinculo	109	21	Sem vinculo	109	21	Sem vinculo	109	21
3	2	204	2020-11-04	PR	87	25	Junior	5282.18	Estatas	Historia	Iniciativa Privada	8	31	0	0
4	3	201	2020-11-21	SC	98	28	Sem vinculo	0	Humanas	Desempenho	Iniciativa Privada	5	100	0	0
5	4	203	2020-08-24	RJ	20	25	Junior	2376.19	Estatas	Presencial	Sector Publico	5	21	0	0
6	5	103	2020-02-02	SP	112	20	Geobio	10143.79	Tecnologia	Presencial	Iniciativa Privada	9	82	1	0
7	6	104	2020-02-02	SP	77	20	Geobio	16170.07	Tecnologia	Presencial	ONG	5	84	1	0
8	7	101	2020-05-17	PR	86	27	Senior	12145.15	Tecnologia	Presencial	Iniciativa Privada	5	99	0	0
9	8	101	2020-11-30	SC	26	28	Plano	5125.08	Tecnologia	EAD	Iniciativa Privada	5	20	0	0
10	9	103	2020-01-11	SP	105	24	Geobio	17082.71	Tecnologia	EAD	AutodromoPJ	5	79	0	0
11	10	302	2020-04-22	SP	88	32	Sem vinculo	0	Humanas	Presencial	Desempenho	5	95	0	0
12	11	403	2020-02-03	GO	82	27	Geobio	18843.01	Biologicos	EAD	Iniciativa Privada	5	20	0	0
13	12	303	2020-04-03	SC	80	33	Geobio	15076.08	Humanas	EAD	Iniciativa Privada	10	27	1	1
14	13	303	2020-02-04	BA	80	27	Senior	12382.27	Humanas	EAD	AutodromoPJ	8	18	0	0
15	14	203	2020-02-13	PR	93	29	Geobio	16132.06	Estatas	EAD	Sector Publico	8	13	1	0
16	15	104	2020-10-31	SP	105	35	Geobio	17085.8	Tecnologia	EAD	ONG	8	86	0	0
17	16	101	2020-07-11	MG	109	36	Senior	8070.4	Tecnologia	Presencial	Sector Publico	9	23	0	0
18	17	104	2020-01-18	MG	28	23	Plano	4356.88	Tecnologia	EAD	Iniciativa Privada	6	19	0	0
19	18	304	2020-06-17	SP	8	27	Sem vinculo	0	Humanas	EAD	Desempenho	10	31	1	0
20	19	404	2020-08-07	RJ	27	29	Junior	1824.79	Biologicos	Presencial	Iniciativa Privada	5	73	0	0
21	20	203	2020-12-04	PR	58	29	Plano	8206.38	Estatas	Presencial	Iniciativa Privada	8	51	1	0
22	21	302	2020-06-08	SP	7	25	Junior	2385.1	Estatas	Presencial	Iniciativa Privada	6	84	0	0
23	22	201	2020-09-23	PR	93	30	Senior	13489.3	Estatas	Presencial	Sector Publico	6	94	1	0
24	23	202	2020-02-08	MG	113	35	Geobio	15191.28	Estatas	EAD	Iniciativa Privada	7	51	1	0
25	24	304	2020-09-18	BA	20	27	Plano	8915.79	Humanas	Presencial	AutodromoPJ	5	100	1	0
26	25	304	2020-07-18	SP	43	30	Senior	12382.08	Humanas	Presencial	Iniciativa Privada	7	37	1	0
27	26	302	2020-03-18	SP	7	23	Junior	4887.38	Humanas	Presencial	Iniciativa Privada	7	78	0	0
28	27	302	2020-08-01	MG	89	31	Geobio	17087.04	Humanas	Presencial	AutodromoPJ	8	94	1	1
29	28	202	2020-04-04	SP	85	29	Senior	15871.84	Estatas	EAD	Iniciativa Privada	9	91	1	0
30	29	404	2020-05-02	PR	26	25	Plano	7176.13	Biologicos	EAD	Iniciativa Privada	6	9	0	0
31	30	304	2020-07-25	PR	38	23	Junior	2843.81	Humanas	Presencial	Iniciativa Privada	5	89	0	0
32	31	201	2020-07-28	SP	81	28	Sem vinculo	0	Estatas	Historia	Desempenho	5	14	1	0
33	32	201	2020-12-08	RJ	83	29	Plano	4522.31	Estatas	Presencial	Iniciativa Privada	5	48	0	0
34	33	404	2020-08-08	RJ	27	25	Plano	8038.08	Biologicos	EAD	Iniciativa Privada	9	90	1	0
35	34	202	2020-05-18	PR	113	30	Geobio	16144.01	Estatas	EAD	Iniciativa Privada	7	9	0	0
36	35	202	2020-01-08	GO	94	21	Geobio	18229.24	Estatas	Presencial	Iniciativa Privada	4	20	1	0

Figura 3 – Dataset egressos (csv) gerado de Plataforma ERP da instituição.

2. Carga do Dados (Etapa 4.2)

Inicialmente, havia pensado em fazer um Job no Databricks para automatizar a ingestão de dados incremental, porém achei melhor subir os datasets manualmente, já que ainda precisaria de uma autorização do Conselho Diretor para a continuidade da geração dos dados, para além dos 11.660 que tive de autorização como base de uma POC. Diante disso, fiz a ingestão direta dos arquivos em Volume do Unity Catalog da Camada Bronze (utilizei a Estrutura Medalhão para aplicação do pepiline). E a partir dele, gerei as tabelas bronze como mostrado pelo código pyspark.sql a seguir.

```

# Carga BRONZE - Ingestão direta do Volume
# Databricks notebook source
# COMMAND -----
from pyspark.sql.functions import current_timestamp, lit

# Caminho base do Volume
volume_path = "/Volumes/mvp_eng_dados/bronze/base_dados"

# 1. Ingestão do Dataset Egressos direto do CSV no Volume
df_egressos_bronze_raw = (
    spark.read
    .format("csv")
    .option("header", "true")
    .option("inferSchema", "true")
    .load(f"{volume_path}/dataset_egressos_posgrad_erp.csv")
    .withColumn("data_ingestao", current_timestamp())
    .withColumn("arquivo_origem", lit(f"{volume_path}/dataset_egressos_posgrad_erp.csv"))
)

# 2. Ingestão do Dataset Cursos direto do CSV no Volume
df_cursos_bronze_raw = (
    spark.read
    .format("csv")
    .option("header", "true")
    .option("inferSchema", "true")
    .load(f"{volume_path}/dataset_cursos.csv")
    .withColumn("data_ingestao", current_timestamp())
    .withColumn("arquivo_origem", lit(f"{volume_path}/dataset_cursos.csv"))
)

# Criação do schema bronze se não existir
spark.sql("CREATE SCHEMA IF NOT EXISTS mvp_eng_dados.bronze")

```

Figura 4 – Tela do Databricks demonstrando a ingestão direta de dados via Camada Bronze

Também insiro aqui o código utilizado para a Camada Bronze que pode ser encontrado no notebook no link do GitHub:

https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/01_camada_bronze.ipynb.

```

# CAMADA BRONZE - Ingestão direta do Volume
# Databricks notebook source
# COMMAND -----
from pyspark.sql.functions import current_timestamp, lit

# Caminho base do Volume
volume_path = "/Volumes/mvp_eng_dados/bronze/base_dados"

# 1. Ingestão do Dataset Egressos direto do CSV no Volume
df_egressos_bronze_raw = (
    spark.read
    .format("csv")
    .option("header", "true")
    .option("inferSchema", "true")
    .load(f"{volume_path}/dataset_egressos_posgrad_erp.csv")
    .withColumn("_data_ingestao", current_timestamp())
    .withColumn("_arquivo_origem", lit(f"{volume_path}/dataset_egressos_posgrad_erp.csv"))
)

# 2. Ingestão do Dataset Cursos direto do CSV no Volume
df_cursos_bronze_raw = (
    spark.read
    .format("csv")
    .option("header", "true")
    .option("inferSchema", "true")
    .load(f"{volume_path}/dataset_cursos.csv")
    .withColumn("_data_ingestao", current_timestamp())
    .withColumn("_arquivo_origem", lit(f"{volume_path}/dataset_cursos.csv"))
)

# Criação do schema bronze se não existir
spark.sql("CREATE SCHEMA IF NOT EXISTS mvp_eng_dados.bronze")

# Gravação nas tabelas Delta Bronze (com overwriteSchema para corrigir tipos)
df_egressos_bronze_raw.write.mode("overwrite").option("overwriteSchema",
"true").saveAsTable("mvp_eng_dados.bronze.dataset_egressos_bruto")
df_cursos_bronze_raw.write.mode("overwrite").option("overwriteSchema",
"true").saveAsTable("mvp_eng_dados.bronze.dataset_cursos_bruto")

```

3. Modelagem e Catálogo de Dados (Etapa 4.3)

A estruturação da plataforma de dados foi concebida utilizando o padrão de **Arquitetura Medallion** em um ambiente **Databricks Delta Lake**. Esta abordagem garante a rastreabilidade, qualidade e governança da informação à medida que os dados brutos progridem até a disponibilização em modelos analíticos de alta performance. Para isso, foi aplicada a modelagem dimensional do tipo Estrela como detalhado a seguir.

3.1. Modelagem Dimensional (Esquema Estrela)

Esta modelagem foi aplicada a partir da camada Gold (https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/03_camada_gold.ipynb) que serviu para reorganizar os dados limpos da Silver em tabelas fato e dimensões, otimizando a execução de consultas agregadas. A imagem a seguir demonstra o notebook em que esta modelagem foi aplicada.




Figura 5 – Demonstração do notebook no Databricks em que foi aplicada a Modelagem Estrela.

Para criar o Diagrama de Relacionamento de Entidades (DRE) (Figura 6) caracterizando o modelo aplicado, em um notebook separado (https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/04_constraints_gold_output.ipynb) foi documentado os comandos DDL para criação de Primary Keys (PK) e Foreign Keys (FK) nas tabelas da camada Gold do modelo Estrela.




Figura 6 – Demonstração do notebook no Databricks em que foram aplicados os comandos DDL Constraints para Chaves PK e FK, com intuito de verificar o DRE.

Com a identificação das PKs e FKs nas tabelas gold, foi possível ver graficamente os relacionamentos como demonstrado na imagem a seguir (Figura 7).




Figura 7 – Diagrama de relacionamento de entidade (tabelas, atributos, PK e FK).

- **Tabela Fato (*fato_egressos*):** Contém a granularidade do registro individual de acompanhamento do egresso. Consolida as chaves estrangeiras (*id_egresso*, *id_curso*, *id_emplo*) e armazena métricas quantitativas e atributos categorizados:
 - Métricas numéricas: *renda_mensual_estimada*, *satisfacao_graduacao_nps*, *engajamento_alumni_score* e *meses_desde_formacao*.
 - Atributos analíticos derivados: *categoria_nps* (*Promotor*, *Neutro*, *Detrator*) e *faixa_meses_formacao* (agrupamentos temporais de pós-formação).
- **Tabelas de Dimensão:**
 - ***dim_egresso*:** Armazena o perfil demográfico do ex-aluno (*id_egresso* [PK], *idade_egresso*, *uf_residencia*, *bolsista_graduacao*).
 - ***dim_curso*:** Cataloga os dados acadêmicos e financeiros do curso (*id_curso* [PK], *nome_curso*, *area_conhecimento*, *duracao_semestres*, *mensalidade_base*, *modalidade_graduacao*).
 - ***dim_emplo*:** Dimensão categorizada para mercado de trabalho, identificada por uma *Surrogate Key* calculada via Hash MD5 (*id_emplo* [PK Hash], *nivel_cargo*, *tipo_empresa*).

3.2. Catálogo de dados

A seguir, apresento o **catálogo de dados** apenas da Camada Gold que foi gerado na plataforma Databricks. Optei por apresentar apenas a última camada, haja vista ser a camada final do pipeline e as anteriores se repetirem nessa.

A camada foi composta de nove dataframes: 1 tabela fato, 3 tabelas dimensão e 5 tabelas KPI para responderem as perguntas de negócio levantadas.

Nome	Proprietário	Criada às	Popularidade	Comment
dim_curso	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:40	✓	A tabela contém informaço...
dim_egresso	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:40	✓	A tabela contém informaço...
dim_emplo	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:40	✓	A tabela contém informaço...
fato_egressos	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:40	✓	A tabela fornece dados sobr...
kpi_conversao_tempo_bolsa	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:41	✓	A tabela fornece dados sobr...
kpi_engajabilidade_roi_curso	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:41	✓	A tabela fornece dados sobr...
kpi_engajabilidade_roi_emplo	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:41	✓	A tabela fornece dados sobr...
kpi_engajamento_alumni	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:41	✓	Esta tabela contém informaço...
kpi_perfil_profissional_uf	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:41	✓	A tabela contém informaço...
kpi_potencial_pos_graduacao	elisandra.maranhe@gmail.com	12 de set. de 2026, 12:40	✓	A tabela contém dados sobr...

Figura 8 – Estrutura de tabelas geradas a partir do Modelo Estrela dentro do Databricks.

Catálogo de Dados da tabela *fato_egressos*:

Pesquise dados, notebooks, recentes e muito mais...

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

fato_egressos

☆

Visão geral

Dados de exemploDetalhesPermissõesPolíticasHistóricoLinhagemInsightsQualidade

Descrição

A tabela fornece dados sobre egressos de cursos, incluindo informações sobre formação e situações profissionais atuais. É possível utilizá-la para analisar a renda mensal estimada dos egressos, a satisfação com a graduação, o engajamento dos alumni e o tempo decorrido desde a formação. Os dados também permitem avaliar o potencial de matrícula em cursos de pós-graduação, ajudando a entender o impacto da formação no mercado de trabalho.

Filtrar colunas...

Ver relacionamentos

Coluna	Tipo	Comentário
id_egresso	int	Identificador único de cada egresso, utilizado para diferenciar os indivíduos na tabela e relacioná-los com outras informações.
id_curso	int	Identificador do curso de formação que o egresso completou, permitindo a análise por área de estudo.
id_emprego	string	Identificador do emprego atual do egresso, utilizado para relacionar os dados de formação com a situação profissional.
dt_ultimo_contato	timestamp	Data e hora do último contato feito com o egresso, ajudando a entender o engajamento e atualizações nas informações.
renda_mensal_estimada	decimal(10,2)	Valor estimado da renda mensal que os egressos estão recebendo, importante para análises de retorno sobre investimento em educação.
satisfacao_graduacao_nps	int	Pontuação de satisfação do egresso com a graduação, medida através do Net Promoter Score (NPS), que indica a disposição de recomendar o curso.
categoria_nps	string	Classificação do egresso conforme a categoria de NPS, que pode incluir promotores, passivos e detratores.
engajamento_alumni_score	int	Pontuação que mede o nível de engajamento dos egressos com a instituição, contribuindo para estratégias de alumni.
potencial_matricula_pos	int	Indicador que estima a probabilidade de o egresso se matricular em um curso de pós-graduação, auxiliando no planejamento de ofertas acadêmicas.
meses_desde_formacao	int	Quantidade de meses que se passaram desde a formação do egresso, relevante para análises de tempo e mercado de trabalho.
faixa_meses_formacao	string	Intervalo de meses em que a formação do egresso ocorreu, permitindo avaliar a situação dos egressos conforme a proximidade da formatura.

Catálogo de Dados da tabela *dim_curso*:

data

data

bricks

Free Edition

Q

Pesquise dados, notebooks, recentes e muito mais...

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

dim_curso

☆

Abrir em um das

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

A tabela contém informações sobre cursos disponíveis. Os dados incluem o nome do curso, a área de conhecimento, a duração em semestres, a mensalidade base e a modalidade de graduação. Possíveis usos incluem análise de oferta de cursos, comparação de custos e avaliação de gama de disciplinas oferecidas.

Q

Filtrar colunas...

Coluna	Tipo	Comentário	
id_curso PK	int	Identificador único do curso, utilizado para distinguir cada curso na tabela.	
nome_curso	string	O nome completo do curso, útil para identificar e descrever o conteúdo educacional oferecido.	
area_conhecimento	string	Refere-se à área de estudo relacionada ao curso, permitindo a categorização dos cursos por disciplina.	
duracao_semestres	int	Indica a duração do curso em semestres, o que ajuda na avaliação do compromisso de tempo necessário para a conclusão.	
mensalidade_base	decimal(10,2)	Representa o valor mensal a ser pago para cursar, fundamental para análise de custos e viabilidade financeira.	
modalidade_graduacao	string	Descreve a forma de formação acadêmica oferecida pelo curso, importante para entender as opções disponíveis aos alunos.	

Catálogo de Dados da tabela *dim_egressos*:

data

data

base

Explorador de Catálogos > mvp_eng_dados > gold >

dim_egresso

Abrir em um dashboard

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

A tabela contém informações sobre egressos, incluindo dados demográficos e de residência. Possíveis usos incluem análise de perfis de egressos, avaliação de programas de bolsa e estudo de deslocamento geográfico após a graduação.

Filtrar colunas...

Coluna	Tipo	Comentário
id_egresso PK	int	Identificador único associado a cada egresso, permitindo rastrear informações específicas sobre indivíduos ao longo do tempo.
idade_egresso	int	Indica a idade do egresso no momento da coleta dos dados, possibilitando análises demográficas e de faixa etária.
uf_residencia	string	Representa a unidade federativa onde o egresso reside atualmente, essencial para estudos sobre distribuição geográfica e mobilidade.
bolsista_graduacao	int	Demonstrates whether the graduate received a scholarship during their studies, useful for evaluating the impact of financial aid programs.

Catálogo de Dados da tabela *dim_emprego*:

databricks

Free Edition

Pesquise dados, notebooks, recentes e muito mais...

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

dim_empresa

☆

⋮ Abrir em uma nova aba

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

A tabela contém informações sobre empregos, incluindo detalhes como o nível do cargo e o tipo da empresa. Pode ser utilizada para análises relacionadas à estrutura de cargos, comparação entre tipos de empresas e para entender a distribuição de funções na organização.

Filtrar colunas...

Coluna	Tipo	Comentário	
id_empresa PK	string	Identificador único de cada emprego na tabela, permitindo rastrear informações específicas relacionadas a uma posição de trabalho.	
nível_cargo	string	Representa o nível hierárquico do cargo, proporcionando uma visão sobre a estrutura organizacional e a distribuição de responsabilidades.	
tipo_empresa	string	Classifica o tipo de empresa, utilizado para análises comparativas entre diferentes setores e modelos de negócios.	

Catálogo de Dados da tabela *kpi_conversao_tempo_bolsa*:

databricks

Free Edition

Pesquisar dados, notebooks, recentes e muito mais...CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

kpi_conversao_tempo_bolsa

☆

⋮

Abriu em um dashboard

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição✎

A tabela fornece dados sobre o desempenho de bolsistas ao longo do tempo de formação. Os possíveis usos incluem a análise da taxa de egressos graduados e a avaliação do potencial pós-formação. Ela registra informações como as diferentes faixas de meses de formação, o número de bolsistas que se graduaram, o total de egressos e o total de potenciais formados, além da taxa de potencial pós-formação em porcentagem.

Filtrar colunas...

Coluna	Tipo	Comentário	
faixa_meses_formacao	string	Representa as diferentes faixas de meses que os bolsistas levaram para completar sua formação, permitindo a análise do tempo de conclusão.	
bolsista_graduacao	int	Indica o número de bolsistas que conseguiram se graduar dentro do período analisado.	
total_egressos	bigint	Refere-se ao total de egressos que saíram do programa, independentemente de terem se graduado ou não.	
total_potencial_pos	bigint	Quantidade total de egressos considerados como potenciais formados, que podem ter oportunidades após a formação.	
taxa_potencial_pos_pct	double	Expressa a taxa em porcentagem que representa a proporção do total de egressos que foram considerados como potenciais formados.	

Catálogo de Dados da tabela `kpi_employabilidade_roi_curso`:

data

bricks

free edition

Q

Pesquise dados, notebooks, recentes e muito mais...

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

kpi_employability_roi_course

☆

Abrir em um dashboard

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

A tabela fornece dados sobre a empregabilidade relacionada a cursos e seus impactos financeiros. Os principais elementos a serem analisados incluem a renda média dos egressos, mensalidades dos cursos e a relação entre ROI e rendimento. Possíveis usos incluem a avaliação da viabilidade de cursos, comparação entre modalidades de graduação, e análise das taxas de empregabilidade em diferentes tipos de empresas.

Q

Filtrar colunas...

Coluna	Tipo	Comentário	
nome_curso	string	O nome completo do curso, útil para identificar e descrever o conteúdo educacional oferecido.	
modalidade_graduacao	string	Indica o formato em que o curso é oferecido, como presencial ou online, importante para entender a acessibilidade e as preferências dos alunos.	
nivel_cargo	string	Refere-se à posição ou nível profissional que os egressos ocupam após a conclusão do curso, ajudando na análise da trajetória de carreira dos formados.	
tipo_empresa	string	Representa o setor ou tipo de empresa onde os egressos estão empregados, proporcionando insights sobre a empregabilidade e o mercado de trabalho.	
mensalidade_base	decimal(10,2)	Representa o valor mensal a ser pago para cursar, fundamental para análise de custos e viabilidade financeira.	
qtd_egressos	bigint	Indica a quantidade de alunos que se formaram no curso, um dado relevante para avaliar a popularidade e o alcance do programa educacional.	
renda_media	decimal(11,2)	O valor médio que os egressos ganham após a graduação, essencial para medir o retorno sobre o investimento em educação.	
razao_roi_renda_mensalidade	decimal(14,2)	Representa a relação entre o retorno sobre o investimento e o valor da mensalidade do curso, proporcionando uma métrica para avaliar a eficácia financeira do curso.	

Catálogo de Dados da tabela *kpi_nps_engajamento_alumni*:

databricks

Free Edition

Pesquise dados, notebooks, recentes e muito mais...

CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

kpi_nps_engajamento_alumni

☆

Abrir em uma nova aba

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade

Descrição

Esta tabela contém informações sobre o engajamento de alumni e suas percepções sobre a satisfação com a graduação. É útil para analisar a categoria de satisfação dos ex-alunos, a média de engajamento e a taxa de potencial de pós-graduação. As informações podem ser usadas para entender melhor as experiências dos graduados e informar iniciativas de engajamento.

Filtrar colunas...

Coluna	Tipo	Comentário	
categoria_nps	string	Representa a categoria de Net Promoter Score (NPS), utilizada para classificar o nível de recomendação dos alumni em relação à graduação.	
satisfacao_graduacao_nps	int	Indica o nível de satisfação dos ex-alunos com a graduação, medido em uma escala numérica.	
modalidade_graduacao	string	Refere-se ao tipo de graduação que o alumni completou, como bacharelado, tecnólogo ou outro.	
total_egressos	bigint	O total de alumni que se formaram e cujas opiniões sobre a graduação estão sendo consideradas.	
media_engajamento_alumni	double	Calcula a média do nível de engajamento dos alumni, refletindo sua participação e interação com a instituição após a graduação.	
total_potencial_pos	bigint	Número total de alumni que possuem potencial para continuar seus estudos em pós-graduação.	
taxa_potencial_pos_pct	double	Representa a porcentagem do total de alumni que são considerados potenciais candidatos a programas de pós-graduação.	

Catálogo de Dados da tabela *kpi_perfil_profissional_uf*:

databricks

PREMIUM EDITION

Q Pesquise dados, notebooks, recentes e muito mais... CTRL + P

Explorador de Catálogos > mvp_eng_dados > gold >

kpi_perfil_profissional_uf

⌵ ☆

⋮ Abrir em uma nova aba

Visão geral

Dados de exemplo

Detalhes

Permissões

Políticas

Histórico

Linhagem

Insights

Qualidade


Descrição

A tabela contém informações sobre perfis profissionais por unidade federativa (UF). Os dados incluem área de atuação, nível do cargo, tipo de empresa, quantidade de egressos e informações econômicas como renda média e taxa potencial de posicionamento percentual. Possíveis uso incluem análises de mercado de trabalho em diferentes regiões, avaliação de oportunidades de formação e entender as dinâmicas salariais em diversas áreas.

Filtrar colunas...

Coluna	Tipo	Comentário	
uf_residencia	string	Representa a unidade federativa onde o profissional reside, permitindo análises regionais sobre o mercado de trabalho.	
area_atuacao	string	Indica a área de atuação profissional, ajudando a compreender as diferentes oportunidades de emprego disponíveis em cada setor.	
nivel_cargo	string	Refere-se ao nível hierárquico do cargo ocupado pelo profissional, essencial para entender a distribuição e evolução de carreiras nas diversas áreas.	
tipo_empresa	string	Classifica o tipo de empresa onde o profissional atua, fornecendo insights sobre o ambiente de trabalho e oportunidades de emprego em diferentes setores.	
qtd_egressos	bigint	Representa a quantidade de egressos, ou seja, profissionais formados que atuam na área, permitindo avaliar a saturação do mercado.	
total_potencial_pos	bigint	Indica o total de posições potenciais disponíveis no mercado para a área de atuação, ajudando a entender as oportunidades de emprego.	
renda_media	decimal(11,2)	Apresenta a renda média dos profissionais na área, facilitando análises sobre a remuneração e condições econômicas em diferentes setores.	
media_meses_formado	double	Refere-se à média de meses desde a formação dos profissionais, oferecendo uma perspectiva sobre o tempo de ingresso no mercado de trabalho.	
taxa_potencial_pos_pct	double	Indica a taxa potencial de posicionamento percentual dos profissionais na área, útil para avaliar a competição e as chances de colocação no mercado.	

Catálogo de Dados da tabela *kpi_potencial_pos_graduacao*:



Explorador de Catálogos > mvp_eng_dados > gold >

kpi_potencial_pos_graduacao ✎ ☆

Visão geral Dados de exemplo Detalhes Permissões Políticas Histórico Linhagem Insights Qualidade

Descrição ✎

A tabela contém dados sobre cursos de pós-graduação e seu potencial. Inclui informações sobre o nome do curso, área de conhecimento, modalidade de graduação, total de egressos e o potencial estimado para pós-graduação. Além disso, apresenta métricas como a média do NPS (Net Promoter Score) e a taxa percentual de potencial para pós-graduação. Possíveis usos incluem análise de demanda por cursos de pós-graduação e avaliação do desempenho de diferentes áreas do conhecimento.

Filtrar colunas...

Coluna	Tipo	Comentário
nome_curso	string	O nome completo do curso, útil para identificar e descrever o conteúdo educacional oferecido.
area_conhecimento	string	Refere-se à área de estudo relacionada ao curso, permitindo a categorização dos cursos por disciplina.
modalidade_graduacao	string	Indica o tipo de graduação oferecido, o que pode incluir opções como presencial, online ou híbrido.
total_egressos	bigint	Número total de alunos que concluíram o curso, importante para medir o impacto e a popularidade do mesmo.
total_potencial_pos	bigint	Quantidade estimada de alunos que poderiam ingressar em cursos de pós-graduação, refletindo o potencial de demanda por essas opções.
media_nps	double	A média do Net Promoter Score, que mensura a lealdade dos alunos e sua disposição em recomendar o curso a outras pessoas.
taxa_potencial_pos_pct	double	Representa a taxa percentual do potencial estimado para pós-graduação, fornecendo uma visão clara sobre a viabilidade de novos ingressantes.

4. Pipeline de Dados (Etapa 4.4)

O processo de pipeline ETL foi feito em uma Estrutura Medalhão e cada uma das camadas foi colocada em um notebook diferente, que está sendo descrito a seguir, com seus respectivos links de acesso do GitHub.




Figura 9 – Demonstração das camadas criadas em notebooks separados.

4.1. Arquitetura em Camadas (Pipeline de Dados)

- **Camada Bronze (Raw Ingestion)**
(https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/01_camada_bronze.ipynb): Atua como repositório de persistência dos dados brutos consumidos diretamente das fontes originais (arquivos CSV armazenados em Volumes). Os dados das tabelas *bronze.dataset_egressos_bruto* e *bronze.dataset_cursos_bruto* são gravados em formato Delta no modo *overwrite*, recebendo atributos de auditoria como *_data_ingestao* e *_arquivo_origem* para assegurar total linhagem (*lineage*).
- **Camada Silver (Cleansed & Refined)**
(https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/02_camada_silver.ipynb): Responsável pela higienização, tipagem estrita e aplicação de regras de qualidade e sanidade de dados.
 - **Sanitização de limites:** Valores de *idade_egresso* fora do intervalo biológico de 16 a 100 anos e *renda_mensal_estimada* menores que zero são invalidados (convertidos para NULL).
 - **Tratamento de texto e deduplicação:** Strings foram padronizadas via remoção de espaços sobressalentes (TRIM) e conversão para maiúsculas (UPPER). As duplicatas foram eliminadas com base na unicidade dos registros de negócio.
 - **Atualização idempotente:** As tabelas sanitizadas (*silver.dataset_egressos* e *silver.dataset_cursos*) garantem integridade estrutural para a camada analítica.
- **Camada Gold (Curated & Data Marts)**
(https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/03_camada_gold.ipynb): Camada final voltada ao consumo analítico e *Business Intelligence*, estruturada sobre um **Modelo Dimensional em Esquema Estrela (Star Schema)** no banco *mvp_eng_dados.gold*.

As camadas foram integradas por meio de código como mostrado a seguir:

```
1: Camada Bronze - Processamento Completo

# CAMADA BRONZE - Ingestão direta do Volume
# Databricks notebook source
# COMMAND -----
from pyspark.sql.functions import current_timestamp, lit

# Caminho base do Volume
volume_path = "/Volumes/mvp_eng_dados/bronze/base_dados"

# 1. Ingestão do Dataset Egressos direto do CSV no Volume
df_egressos_bronze_raw = (
    spark.read
        .format("csv")
        .option("header", "true")
        .option("inferSchema", "true")
        .load(f"{volume_path}/dataset_egressos_posgrad_erp.csv")
        .withColumn("_data_ingestao", current_timestamp())
        .withColumn("_arquivo_origem", lit(f"{volume_path}/dataset_egressos_posgrad_erp.csv"))
)
```

```
15 de set. de 2026 (22s) 1: Camada Silver - Processamento Completo

# CAMADA SILVER
# Databricks notebook source
# COMMAND -----
from pyspark.sql.functions import col, to_timestamp, trim, upper, when, current_timestamp, hash, concat_ws, abs
from delta.tables import DeltaTable

# Garante criação do schema Silver se não existir
spark.sql("CREATE SCHEMA IF NOT EXISTS mvp_eng_dados.silver")

# =====
# 1. TRATAMENTO DA TABELA FATO EGRESSOS
# =====

# 1. Leitura da tabela Bronze
df_bronze_egressos = (
    spark.read.table("mvp_eng_dados.bronze.dataset_egressos_bruto")
    # Remove duplicatas por atributos de negócio (mantém apenas um registro por combinação única)
    .dropDuplicates([
        "id_curso", "dt_ultimo_contato", "uf_residencia",
        "meses_desde_formacao", "idade_egresso", "nivel_cargo",
        "renda_mensal_estimada", "area_atuacao", "modalidade_graduacao",
        "tipo_empresa", "satisfacao_graduacao_nps", "engajamento_alumni_score",
        "bolsista_graduacao", "potencial_matricula_pos"
    ])
)
```

```
Há 2 minutos (1min) 1: Camada Gold - Processamento Completo

# CAMADA GOLD
# Databricks notebook source
# COMMAND -----
# 1. IMPORTS E CONFIGURAÇÃO INICIAL
from pyspark.sql.functions import col, count, sum, avg, round, md5, concat_ws, when

# Garante a criação do schema gold
spark.sql("CREATE SCHEMA IF NOT EXISTS mvp_eng_dados.gold")

# Leitura das fontes tratadas na camada Silver
df_silver_egressos = spark.read.table("mvp_eng_dados.silver.dataset_egressos")
df_silver_cursos = spark.read.table("mvp_eng_dados.silver.dataset_cursos")

# COMMAND -----
# 2. MODELAGEM DIMENSIONAL (ESQUEMA ESTRELA)

# 2.1 Dimensão: Egresso
```

Vale também ressaltar que todas as tabelas geradas em cada camada foram salvas (persistidas) na plataforma Databricks em nuvem, como mostra a imagem a seguir.




Figura 10 – Tabelas das camadas medalhão persistidas no Databricks

4.2. Data Marts de KPIs e Otimização Física

Para atender de forma direta e rápida às questões de negócio da instituição, foram construídas dataframes agregados de segundo nível na Camada Gold (*kpi_potencial_pos_graduacao*, *kpi_conversao_tempo_bolsa*, *kpi_employabilidade_roi_curso*, *kpi_nps_engajamento_alumni* e *kpi_perfil_profissional_uf*).

Como estratégia de otimização de leitura e diminuição de *data scanning*, foi aplicado o recurso de **Z-Ordering** nas tabelas físicas do Delta Lake. Esta arquitetura garante que a plataforma atue como uma Fonte Única da Verdade (SSOT), aliando governança no consumo bruto e performance no processamento analítico.

É possível visualizar o código aplicado para isso na camada gold acessando o link no GitHub:

https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/03_camada_gold.ipynb.

5. Qualidade de Dados (Etapa 4.5)

Apresento a seguir a análise técnica detalhada dos problemas identificados no pipeline de ingestão bruta (Camada *Bronze*) e a explicação completa de como cada inconsistência foi resolvida durante o processamento para a Camada *Silver* (*mvp_eng_dados.silver*).

O objetivo central desta etapa do pipeline ETL foi garantir a qualidade, integridade relacional, conformidade do schema (*schema enforcement*) e sanidade das regras de negócio antes que os dados fossem disponibilizados para consumo analítico.

5.1. Visão Geral do Pipeline na Camada Silver

A Camada *Silver* atua como a camada de limpeza, padronização e enriquecimento. No script PySpark (https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/02_camada_silver.ipynb), foram processadas duas entidades principais originadas do catálogo Delta:

- **Fato Egressos** (mvp_eng_dados.bronze.dataset_egressos_bruto > mvp_eng_dados.silver.dataset_egressos).
- **Dimensão Cursos** (mvp_eng_dados.bronze.dataset_cursos_bruto > mvp_eng_dados.silver.dataset_cursos).

5.2. Problemas Detectados e Soluções Aplicadas no Dataset de Egressos

A. Registros Duplicados na Origem Bruta

- **Problema Detectado:** Existência de linhas totalmente duplicadas ou reincidentes na camada *Bronze*, o que geraria distorções em métricas agregadas na camada analítica.
- **Resolução e Transformação:** Foi aplicada a função `.dropDuplicates()` considerando o conjunto explícito de atributos de negócio (`id_curso`, `dt_ultimo_contato`, `uf_residencia`, `meses_desde_formacao`, `idade_egresso`, `nivel_cargo`, `renda_mensal_estimada`, `area_atuacao`, `modalidade_graduacao`, `tipo_empresa`, `satisfacao_graduacao_nps`, `engajamento_alumni_score`, `bolsista_graduacao` e `potencial_matricula_pos`). Com isso, apenas um registro único por perfil funcional é mantido.

B. Ausência e Incompatibilidade de Chaves Primárias

- **Problema Detectado:** Registros com a chave identificadora do egresso (`id_egresso`) nula ou sem tipagem de inteiro, comprometendo o relacionamento relacional.
- **Resolução e Transformação:**
 - Filtragem estrita dos registros sem identificador válido usando `.filter(col("id_egresso").isNotNull())`.
 - *Casting* explícito das chaves `id_egresso` e `id_curso` para o tipo inteiro (`.cast("int")`).

C. Inconsistência na Formatação de Strings e Espaços Sobressalentes

- **Problema Detectado:** Presença de caracteres em caixa alta e baixa misturados, além de espaços em branco antes ou depois de palavras nos campos de texto (`uf_residencia`, `nivel_cargo`, `area_atuacao`, `modalidade_graduacao`, `tipo_empresa`).
- **Resolução e Transformação:** Aplicação combinada das funções de higienização de texto `upper(trim(col(...)))` para remover espaços excedentes e padronizar todas as cadeias de caracteres em caixa alta.

D. Tipagem Inadequada de Datas e Métricas

- **Problema Detectado:** Datas de contato mantidas em formato *string* ou formato não legível por ferramentas de Business Intelligence.
- **Resolução e Transformação:** Conversão do campo `dt_ultimo_contato` para o tipo temporal estruturado utilizando `to_timestamp()`.

E. Violação de Limites Físicos/Biológicos e Valores Numéricos Fora de Regra

- **Problema Detectado:** Presença de ruídos ou *outliers* como idades negativas ou irreais (ex.: menor que 16 anos ou maior que 100 anos), valores negativos para tempo de formação (`meses_desde_formacao`) e renda mensal estimada negativa (`renda_mensal_estimada`).
- **Resolução e Transformação:** Aplicação de regras condicionais `when(...).otherwise(None)` para higienização e saneamento de dados:
 - `meses_desde_formacao`: se ≥ 0 , mantém o valor convertido em int; caso contrário, atribui None (nulo).
 - `idade_egresso`: validado no intervalo pragmático de 16 a 100 anos. Valores fora do intervalo são convertidos para None.
 - `renda_mensal_estimada`: se ≥ 0 , converte para a precisão financeira `decimal(10,2)`; valores inconsistentes se tornam None.

F. Escalas de Avaliação e Indicadores Fora do Intervalo Válido

- **Problema Detectado:** Pontuações da pesquisa NPS (`satisfacao_graduacao_nps`) contendo valores fora do padrão de 0 a 10.
- **Resolução e Transformação:** Validação condicional `when((col("satisfacao_graduacao_nps") >= 0) & (col("satisfacao_graduacao_nps") <= 10))`, convertendo os válidos para int e saneando pontuações fora da faixa para None. Outras variáveis inteiras (`engajamento_alumni_score`, `bolsista_graduacao`, `potencial_matricula_pos`) também receberam *casting* para int.

G. Ausência de Atributo Analítico Direto sobre Situação Profissional

- **Problema Detectado:** Dificuldade na geração de relatórios diretos sobre taxa de empregabilidade sem a necessidade de avaliar strings da coluna `tipo_empresa` a todo momento.
- **Resolução e Transformação:** Engenharia de atributos (*Feature Engineering*) criando a coluna flag `is_empregado`, atribuindo 0 caso o tipo de empresa padronizado seja "DESEMPREGADO", e 1 para qualquer outro tipo.

5.3. Problemas Detectados e Soluções Aplicadas no Dataset de Cursos

A. Registros sem Identificador e Duplicidade de Chave Primária

- **Problema Detectado:** Presença de registros sem `id_curso` e cursos duplicados na base cadastral.
- **Resolução e Transformação:**
 - Descarte de registros nulos com `.filter(col("id_curso").isNull())`.

- Remoção de duplicatas focada estritamente na chave primária do curso com `.dropDuplicates(["id_curso"])`.
- *Casting* de `id_curso` para `int`.

B. Despadronização dos Nomes e Áreas do Conhecimento

- **Problema Detectado:** Textos dos cursos e áreas de conhecimento com variações de caixa e espaços antes/depois.
- **Resolução e Transformação:** Sanitização com `upper(trim(col("nome_curso")))` e `upper(trim(col("area_conhecimento")))`.

C. Valores Negativos em Duração e Mensalidade

- **Problema Detectado:** Cursos configurados com semestres zerados ou negativos, além de valores de mensalidade base incoerentes.
- **Resolução e Transformação:**
 - `duracao_semestres`: validado para aceitar apenas valores estritamente maiores que zero (> 0), convertidos em `int`.
 - `mensalidade_base`: validado para valores maiores ou iguais a zero (≥ 0), convertidos em `decimal(10,2)`.

5.4. Rastreabilidade, Governança e Estratégia de Carga no Delta Lake

Para atender aos padrões de auditoria e manter o ecossistema Delta Lake consistente, o pipeline implementou duas táticas de gravação e governança:

- **Rastreabilidade de Ingestão (Auditoria):**
 - Em ambas as tabelas (`dataset_egressos` e `dataset_cursos`), foi adicionada a coluna de metadados `_data_processamento_silver` contendo o carimbo de data/hora da execução do ETL (`current_timestamp()`).
- **Estratégias de Persistência Diferenciadas:**
 - **Tabela Fato Egressos:** Utiliza estratégia de carga total com substituição controlada do schema (`write.format("delta").mode("overwrite").option("overwriteSchema", "true")`). Isso assegura que o dataset reconstruído reflita totalmente as regras de saneamento atualizadas.
 - **Tabela Dimensão Cursos:** Utiliza carga idempotente baseada no padrão **MERGE (UPSERT)** via `DeltaTable.merge()`. A condição de cruzamento `target.id_curso = source.id_curso` executa a atualização de registros existentes (`whenMatchedUpdateAll()`) e a inserção de novos cursos (`whenNotMatchedInsertAll()`), evitando qualquer duplicação na ingestão incremental.

Com essas transformações, a camada *Silver* atinge um estado de alta confiabilidade, estruturada sobre um schema bem definido e pronta para alimentar agregações e modelos analíticos na camada *Gold*.

6. Análise de Dados (Etapa 4.5)

Para não tornar esta parte do conteúdo repetitiva e não ser descrito em dois lugares diferentes, peço que as respostas e análise sejam consideradas diretamente pelo notebook que foi criado somente para esta finalidade e que se encontra no seguinte link do GitHub: https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/05_analise_dados_output.ipynb. A análise realizada responde as 11 perguntas que foram divididas em 4 categorias de conhecimento, mas que estão interligadas por um único problema central como apresentado no início desse relatório: **a desconexão entre a gestão do ciclo de vida do (LTV – Lifetime Value) e a previsibilidade de receita na conversão de egressos para a Pós-Graduação.**

7. Autoavaliação

A realização deste MVP de Engenharia de Dados representou uma oportunidade ímpar de consolidar conceitos teóricos e práticos no desenvolvimento de uma arquitetura de dados end-to-end voltada para a solução de um problema real de negócio: a desconexão na gestão do ciclo de vida do aluno (LTV) e a imprevisibilidade de receita na conversão de egressos para a pós-graduação.

A seguir, apresento uma reflexão crítica sobre o alcance dos objetivos, as dificuldades técnicas enfrentadas ao longo da execução e as oportunidades de evolução futura para o enriquecimento deste projeto no meu portfólio profissional.

7.1. Atingimento dos Objetivos Delineados

Ao avaliar o escopo inicial estabelecido junto ao Conselho Diretor da instituição, considero que **os objetivos delineados para esta etapa de Engenharia de Dados foram plenamente atingidos.**

- **Contexto de Negócio e Levantamento de Perguntas (Item 1):** Consegui estruturar um diagnóstico detalhado do problema central, mapeando 11 perguntas de negócio divididas estrategicamente em 4 categorias (*Timing & Propensão*, *Capacidade Financeira*, *Engajamento & Lealdade* e *Atratividade Geográfica*).
- **Respeito às Diretrizes de Privacidade (Item 1.1):** Os datasets originais (11.660 registros de egressos e 16 de cursos) foram adequadamente anonimizados antes do versionamento público e da carga no ecossistema de dados, garantindo conformidade com a LGPD.
- **Ingestão e Governança no Databricks (Itens 2 e 3):** Implementei com sucesso a Arquitetura Medalhão (*Bronze*, *Silver* e *Gold*) no Databricks Delta Lake utilizando o Unity Catalog, além da modelagem dimensional em Esquema Estrela (*Star Schema*) com a criação de tabelas Fato, Dimensão e Data Marts de KPIs.
- **Tratamento e Qualidade dos Dados (Item 5):** Foi possível tratar todas as inconsistências identificadas nos dados brutos — tais como registros duplicados, idades irreais (fora da faixa de 16 a 100 anos), rendas e tempos de formação negativos e pontuações de NPS fora da escala.
- **Geração de Valor Analítico (Item 6):** As transformações e agregações realizadas na camada Gold permitiram responder diretamente a todas as perguntas de negócio formuladas, estabelecendo uma Fonte Única da Verdade (*Single Source of Truth - SSOT*).

7.2. Dificuldades Encontradas na Execução do Trabalho

Durante o desenvolvimento do pipeline, enfrentei desafios técnicos e operacionais que exigiram tomada de decisão e aplicação de boas práticas de engenharia:

1. **Ingestão Manual e Ausência de Pipelines Automatizados:** Como o ERP da instituição não possuía integração direta com ferramentas de automação de ETL nesta fase de Prova de Conceito (POC), a ingestão precisou ser realizada manualmente via arquivos CSV em Volumes do Unity Catalog. Essa limitação evidenciou a necessidade futura de defender perante a gestão a implementação de um conector automatizado.
2. **Alta Inconsistência nos Dados Brutos (Camada Bronze):** O dataset original continha ruídos significativos, incluindo idades biológicas e valores de renda inválidos, duplicidades absolutas de linhas (falha na migração de um ERP para outro) e faltas de padronização em colunas de texto. A resolução desses problemas demandou o desenvolvimento de rotinas rigorosas de sanitização em PySpark na Camada Silver.
3. **Mapeamento de Restrições Relacionais (DDL Constraints) em Delta Lake:** Como o ecossistema Delta Lake trata chaves primárias e estrangeiras de forma informativa/não bloqueante, foi necessário construir um notebook dedicado com DDLs organizadas para garantir a rastreabilidade e a geração correta do Diagrama de Relacionamento de Entidades (DRE).
4. **Otimização do Consumo Analítico:** A necessidade de responder a consultas analíticas complexas sem comprometer o tempo de varredura (*data scanning*) exigiu a aplicação de técnicas de otimização física, como a implementação de *Z-Ordering* nas tabelas Delta da camada Gold.

7.3. Trabalhos Futuros e Evolução do Portfólio

Este MVP estabelece os alicerces de dados sólidos necessários para dar o próximo passo na jornada de análise da instituição. Para enriquecer ainda mais a solução e transformá-la em um projeto de ponta a ponta no meu portfólio de Ciência de Dados, pretendo implementar as seguintes melhorias:

- **Automação do Pipeline de Dados (Orquestração e Ingestão Incremental):**
 - Desenvolver um fluxo automatizado de ingestão (via Databricks Workflows / Jobs ou Apache Airflow) consumindo diretamente de APIs de CRM/ERP.
 - Implementar *Auto Loader* (Databricks) para processamento *streaming* ou micro-batch incremental de novos egressos.
- **Desenvolvimento da Etapa de Machine Learning (Preditiva):**
 - Avançar para a fase preditiva mencionada no planejamento inicial, criando modelos de Machine Learning (Classificação/Propensão) para prever a probabilidade de um egresso se matricular na pós-graduação.
 - Construir modelos de *Clustering* (segmentação preditiva do Alumni) e previsão de *Lifetime Value* (LTV) com base nas variáveis socioeconômicas, geográficas e de engajamento tratadas na camada Gold.
- **Visualização de Dados Dinâmica e Dashboards Executivos:**
 - Conectar os Data Marts de KPIs a uma ferramenta de BI (como Power BI ou Databricks Dashboards) para criar painéis interativos voltados às equipes de Marketing e Finanças da instituição. Fiz um teste com um dashboard do próprio

Databricks, mas que ainda precisa ser lapidado

(https://github.com/elis2637/posgrad_pucrio/blob/main/sprint_engenharia_dados/notebooks/06_dashboard_dados_egressos%202026-09-18%2012_59.pdf).

- **CI/CD e Governança Avançada:**

- Implementar testes automatizados de qualidade de dados (utilizando ferramentas como *Great Expectations* ou *Delta Live Tables*) e controle de versão de código/modelos com MLflow no repositório do GitHub.

A execução deste projeto permitiu atestar a importância do alinhamento entre as necessidades do negócio e a arquitetura de engenharia de dados. Mais do que uma exigência acadêmica, a solução desenvolvida provou seu valor ao transformar dados brutos desestruturados em ativos estratégicos limpos, governados e prontos para alimentar tanto análises diagnósticas quanto futuros modelos preditivos de Inteligência Artificial. Gostei muito da experiência e me sinto segura para prosseguir com os próximos passos.